



Hardware de Audacia
de Comunicación Universitaria

Documentación técnica y guía de replicación

Asistente conversacional local para la exhibición de AudacIA: modelo de lenguaje, recuperación sobre el corpus institucional, voz y ventana de exhibición. Todo en la máquina, sin llamadas externas.

AudacIA · Centro de Excelencia en IA y Robótica

Universidad Simón Bolívar · Barranquilla

Versión de 17 de septiembre de 2026 · suite de regresión 517/517

Índice

1	Presentación	5
	Arrancar en cinco minutos	5
	Qué tiene de particular	6
	Estructura	6
	Limitaciones conocidas	7
	Requisitos	7
2	Instalación desde cero	9
	1. Lo que hace falta antes de empezar	9
	2. Entorno de Python	9
	3. llama-cpp-python con CUDA	10
	3a. Rueda precompilada (empieza por aquí)	10
	3b. Compilar en la máquina	10
	4. El modelo	11
	5. Extras opcionales: ventana y voz	11
	6. Primer arranque y verificación	12
	7. Arrancar como se arranca el día de la exhibición	13
	8. Cuando algo falla	13
3	GitHub: publicar y replicar el proyecto	15
	Qué NO entra en el repositorio, y por qué	15
	A. Publicar el proyecto por primera vez	16
	A.1 Comprobar que no hay nada que no deba subir	16
	A.2 Inicializar y primer commit	16
	A.3 Crear el repositorio remoto	16
	A.4 Marcar la versión que se exhibió	17
	B. Replicar el proyecto en otra máquina	17
	C. Trabajar en el proyecto	18
	Ritmo de trabajo	18
	Mensajes de commit	19
	Cuando cambia el corpus	19
	Ganchos de pre-commit (opcional pero recomendado)	19
	Integración continua	19
	D. Problemas típicos	20
	E. Qué revisar antes de hacer público el repositorio	20
4	Docker: construir, ejecutar y replicar	21
	1. Antes de construir	21
	2. Qué hay dentro de la imagen	22
	Los cuatro --build-arg	23
	3. Construir	23

4. Ejecutar	24
Montar solo lo necesario	24
Con Compose	25
5. Verificar que el contenedor usa de verdad la GPU	26
Por qué la imagen compila en vez de bajar una rueda	26
6. Replicar el proyecto entero con Docker	27
7. Cuando algo falla	27
5 Arquitectura	29
Idea de fondo	29
El recorrido de un turno	29
Los módulos	30
Núcleo	30
Conocimiento	31
Memoria	31
Salida	31
Alrededor	31
Enrutado: tres dominios, uno heredado	32
Profundidad: la pregunta decide cuánto se trae	32
El presupuesto de contexto	33
Cuando el visitante no pregunta nada	33
1. El cierre largo se colaba	34
2. El techo de tokens no distinguía	34
3. Le ponía palabras en la boca al visitante	35
El guardarraíl se disparaba en los seguimientos	35
«No tengo información sobre MacondoLab» (y sí la tenía)	36
El extractor se comía los cierres	37
El injerto que apagaba el guardarraíl	37
Ceder bajo presión, e inventar trámites	37
«No hay nada que discutir. Tu profesor tiene razón.»	38
Los trámites no están en el corpus, y son lo que más preguntan	38
Contaminación: la regla que más veces se ha roto	38
Concurrencia	39
El presupuesto de VRAM	40
La caché KV es la palanca, no los pesos	40
Subir n_ctx a secas no cambia nada	41
Por dónde entrar según lo que quieras cambiar	41
6 Configuración	42
Quién manda sobre quién	42
Variables de entorno	42
Argumentos de run_hacu.py	43
Los bloques de config.py	43
ModelConfig — el modelo	43
RagConfig — el corpus y su recuperación	44
MemoryConfig — la memoria de los visitantes	44
VozConfig — oído y boca	45
InterfazConfig — la ventana	45

AppConfig — la raíz	46
El saludo de apertura	46
Cambiar el presupuesto de contexto sin romperlo	46
7 El corpus: lo que HACU sabe	47
Los dos niveles	47
El corpus no se escribe a mano	48
Documentos escritos a mano junto a los generados	48
El tercer argumento, y por qué avisa	49
Después de cambiar el corpus	49
Advertencias de seguridad de cada montaje	50
Escribir a mano, si hace falta	50
8 La capa de voz	51
Diagnóstico: lo primero que se corre al llegar a la sala	51
Reconocimiento	52
Por qué ya no es small	52
La confianza del reconocedor, registrada	52
Síntesis	53
Cómo se escribe y cómo se dice	53
La pausa que parecía de las tildes	54
El volumen que subía y bajaba	54
Callar a mitad de frase	55
Quién está hablando	55
Una frase rara no cambia de visitante	55
Pulsar para hablar, y por qué es el modo por defecto	56
Solo altavoz	56
Los archivos	56
Limitaciones conocidas	57
9 La ventana de exhibición	58
Teclado	58
El panel del operador (F9)	59
Visitante	59
Audiencia	59
Voz	59
Memoria	60
Qué pasa al arrancar	60
Cómo se verifica sin mirarla	60
Los archivos	61
10 Pruebas	62
test_unidades — la que se corre siempre	62
recuperacion — ¿encuentra HACU lo que tiene documentado?	63
bateria — 60 entradas sueltas	63
conversacion — una visita con hilo	64
Cómo leer un fallo	65
Limpiar después	66

11 El día de la exhibición	67
La noche anterior	67
Al llegar a la sala, antes de levantar el modelo	67
Arrancar	68
Durante la jornada	68
Entre visitante y visitante	68
Ajustar al público	68
Cuando se pone pesado	69
Cuando alguien lo está pasando mal	69
Cuando dice algo raro	69
Si se queda colgado	69
Al cerrar	69
Chuleta	70
12 Datos de los visitantes	71
Qué se guarda	71
Cuando alguien lo está pasando mal	71
Qué NO se guarda	72
Qué filtra el sistema por su cuenta	72
Cómo se borra	72
Lo que hay que decidir antes de una exhibición real	73

Presentación

HACU (*Hardware de Audacia de Comunicación Universitaria*) es un asistente conversacional que responde sobre los proyectos de **AudacIA** y sobre la **Universidad Simón Bolívar** durante una exhibición abierta al público. Escucha por micrófono, responde en voz alta, recuerda a quien tiene delante durante la visita y admite cuando no sabe algo.

Corre **enteramente en local**: el modelo, el índice vectorial y la memoria de los visitantes no salen de la máquina. No hay llamadas a ninguna API.

```
python run_hacu.py --ui --voz --pantalla-completa
```

Arrancar en cinco minutos

```
python -m venv venv
.\venv\Scripts\Activate.ps1
pip install -r requirements.txt
pip install llama-cpp-python --prefer-binary \
  --extra-index-url https://abetlen.github.io/llama-cpp-python/whl/cu121

# El modelo (~4,9 GB) no viene en el repositorio:
#   -> models/Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf

pip install -r requirements-ui.txt      # ventana de exhibición (opcional)
pip install -r requirements-voz.txt    # micrófono y altavoz (opcional)
python -m hacu.voz --descargar          # voz de Piper (~110 MB)

python run_hacu.py --ui --voz
```

La primera ejecución descarga el modelo de embeddings (~470 MB) e indexa el corpus. Las siguientes arrancan directamente.

Paso a paso completo, con verificación y errores típicos: *Instalación desde cero*.

Comando	Qué hace
<code>python run_hacu.py</code>	Consola limpia, diagnóstico al log
<code>python run_hacu.py --debug</code>	Router, perfil activo, latencia y migraciones en pantalla
<code>python run_hacu.py --ui</code>	Ventana de exhibición, sin voz

Comando	Qué hace
<code>python run_hacu.py --voz-salida</code>	Consola: escribes tú, HACU responde en voz alta
<code>python run_hacu.py --ui --voz</code>	Ventana con micrófono y altavoz
<code>python run_hacu.py --ui --voz --pantalla-completa</code>	Lo que se proyecta el día de la exhibición
<code>python -m hacu.voz</code>	Diagnóstico de audio: qué micrófono y qué altavoz
<code>python -m pruebas.test_unidades</code>	742 comprobaciones, ~2 s, sin GPU
<code>python -m herramientas.limpiar</code>	Qué sobra en la carpeta de trabajo
<code>.\iniciar_robot.ps1</code>	Lo mismo dentro de Docker con GPU

Qué tiene de particular

Cuatro niveles de profundidad. Con 32 proyectos, «¿cuáles tienen?», «explícame cada uno» y «cuéntame todo sobre Mary» necesitan cosas distintas. La pregunta decide cuánto se recupera, y el índice-catálogo se carga entero en vez de buscarse — porque buscarlo devolvía 5 proyectos de 32.

No suelta el hilo. Un «¿y eso?» hereda el dominio del turno anterior, y la última respuesta viaja recortada como ancla. Una pregunta sobre HACU mismo no hereda: si no, una pregunta personal arrastraría documentación de un proyecto.

Capas deterministas después del modelo. Coletillas, adulación y fugas del andamiaje se recortan en Python, no se le piden al modelo. Lo que se lee, lo que se oye y lo que se guarda son exactamente el mismo texto.

Se calla cuando le dicen que se calle. El audio se entrega a la tarjeta en trozos de 50 ms: medido, 10 ms hasta detenerse. Quien interrumpe no espera a que termine la frase.

Nota cuándo se acerca otra persona, sin identificar a nadie. La referencia de timbre vive en memoria durante la visita y se borra al cambiar de visitante. No hay huella de voz en disco, y por tanto no hay base biométrica que custodiar.

Cada umbral sale de una medida. No hay un solo número en `config.py` que sea una suposición; al lado de cada uno está qué se midió para elegirlo.

Estructura

run_hacu.py	entrada
hacu/	
bootstrap.py	construye y cablea todo el sistema
cli.py	consola del operador
session.py	orquestación de un turno
identity.py	quién es el visitante; valida nombres, migra perfiles
routing.py	a qué corpus va la pregunta
context.py	qué se le manda al modelo
rag.py	indexación y recuperación sobre ChromaDB
prompts.py	system prompt, saludo y prompts de utilidad
llm.py	único acceso a llama.cpp, serializado
estilo.py	recorte determinista del cierre de turno
extractor.py	memoria episódica en segundo plano
sanitizer.py	qué merece guardarse como hecho
memory.py	persistencia SQLite
config.py	toda la configuración, con su justificación
voz/	micrófono, reconocimiento, síntesis, pronunciación
interfaz/	la ventana de exhibición
documents/	corpus en dos niveles (índice, fichas, institucional)
herramientas/	generación del corpus y limpieza del árbol
pruebas/	suite de regresión y herramientas de medición
docs/	esta documentación

Limitaciones conocidas

- El reconocimiento está medido de extremo a extremo con `--autoprueba` (4/4 nombres propios, ~1,9 s por frase en CPU). Lo que **no** se ha probado es la captura por micrófono real: nivel de entrada, ruido de sala y recorte de la primera sílaba solo se ven con hardware delante.
- Con altavoz abierto, la escucha automática hace que HACU se oiga a sí mismo. Pulsar-para-hablar lo evita; unos auriculares o un micrófono direccional también.
- El router es léxico. Las preguntas de seguimiento sin palabra clave se rescatan por distancia semántica, pero una referencia muy vaga puede traer el fragmento equivocado.
- Los nombres compuestos se limitan a dos palabras.
- Una sola estación: hay un perfil activo a la vez.
- La ruta de Docker no está verificada sobre la RTX 50 de esta máquina; la comprobación que falta está en 5. *Verificar que el contenedor usa de verdad la GPU.*

Requisitos

- GPU NVIDIA con CUDA y ≥ 8 GB de VRAM (desarrollado sobre una RTX 5070 Ti Laptop, 12 GB)
- Python 3.10 – 3.12
- ~12 GB de disco

- `models/Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf`

Corre sin GPU, pero en CPU un turno pasa de segundos a minutos: no sirve para una exhibición.

Instalación desde cero

Levantar HACU en una máquina que no lo ha visto nunca. Al final de esta página el sistema arranca, responde y se le puede hablar.

Si lo que buscas es **replicar el proyecto desde el repositorio**, empieza por *GitHub: publicar y replicar el proyecto* y vuelve aquí en el paso «Entorno de Python». Si prefieres el contenedor, ve a *Docker: construir, ejecutar y replicar*.

1. Lo que hace falta antes de empezar

	Mínimo	Con lo que está desarrollado
GPU	NVIDIA con ≥ 8 GB de VRAM	RTX 5070 Ti Laptop, 12 GB
Controlador	El que soporte tu CUDA	—
RAM	16 GB	32 GB
Disco	~12 GB libres	—
Python	3.10 – 3.12	3.11
Sistema	Windows 10/11 o Linux	Windows 11

HACU corre **sin GPU**, pero en CPU un turno pasa de segundos a minutos: no sirve para una exhibición. El arranque lo dice en la primera línea (`nvidia-smi`).

Comprueba el controlador antes de nada:

```
nvidia-smi
```

La esquina superior derecha de esa tabla dice la **versión de CUDA que soporta tu controlador**. Apúntala: decide qué rueda de llama-cpp-python instalar en el paso 3.

2. Entorno de Python

```
git clone <URL-DEL-REPOSITORIO> voz-rag-universidad
cd voz-rag-universidad

python -m venv venv
.\venv\Scripts\Activate.ps1          # Linux/macOS: source venv/bin/activate
```

```
python -m pip install --upgrade pip
pip install -r requirements.txt
```

Si PowerShell se niega a ejecutar el script de activación:

```
Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass
```

El entorno hay que activarlo **en cada terminal nueva**, no solo la primera vez. Cuando está activo, el prompt lleva (venv) delante; si no lo lleva, python es el del sistema y el arranque falla con `ModuleNotFoundError` en el primer import que no sea de la biblioteca estándar.

requirements.txt instala el núcleo: ChromaDB, los embeddings multilingües y el troceador de texto. **No** instala llama-cpp-python con CUDA — eso es el paso siguiente, porque depende de tu tarjeta.

3. llama-cpp-python con CUDA

Hay dos caminos. El primero tarda un minuto; el segundo, entre diez y cuarenta.

3a. Rueda precompilada (empieza por aquí)

```
pip install llama-cpp-python `
  --prefer-binary `
  --extra-index-url https://abetlen.github.io/llama-cpp-python/whl/cu121
```

Cambia cu121 por la serie que corresponda a tu CUDA (cu122, cu124, cu125...). **Si tu GPU es de la serie RTX 50 (Blackwell), cu121 puede no traer código nativo para tu arquitectura:** funcionará compilando sobre la marcha, o no funcionará en absoluto. Verifica con el paso 6 antes de darlo por bueno.

3b. Compilar en la máquina

Hace falta un compilador de C++ y CMake (en Windows, las *Build Tools for Visual Studio* con la carga de trabajo «Desarrollo para escritorio con C++»).

```
$env:CMAKE_ARGS="-DGGML_CUDA=on"
$env:FORCE_CMAKE="1"
pip install llama-cpp-python --no-cache-dir
```

```
CMAKE_ARGS="-DGGML_CUDA=on" FORCE_CMAKE=1 pip install llama-cpp-python --no-cache-dir
```

Compilar es más lento pero genera código para **tu** tarjeta, así que es la salida cuando ninguna rueda encaja.

4. El modelo

HACU espera este archivo exacto:

models/Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf

Son ~4,9 GB. **No está en el repositorio** y no debe estarlo (ver *Qué NO entra en el repositorio, y por qué*). Se descarga de Hugging Face, de cualquiera de los repositorios que publican la cuantización Q4_K_M de Meta-Llama-3.1-8B-Instruct:

```
pip install huggingface-hub
huggingface-cli download <repo-de-hugging-face> Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf \
  --local-dir models
```

El nombre del repositorio de Hugging Face depende de quién publique la cuantización y cambia con el tiempo; búscalo en <https://huggingface.co/models?search=Meta-Llama-3.1-8B-Instruct-GGUF> y comprueba que el archivo pesa ~4,9 GB. Llama 3.1 exige aceptar su licencia y `huggingface-cli login` antes de descargar.

Otro modelo GGUF sirve sin tocar código:

```
$env:HACU_MODELO="otro-modelo.gguf"      # relativo a models/, o ruta absoluta
$env:HACU_CTX="8192"                    # un modelo mayor deja menos VRAM
```

5. Extras opcionales: ventana y voz

Los dos son **opcionales a propósito**. El núcleo tiene que poder arrancar en una máquina sin tarjeta de sonido y sin entorno gráfico.

```
pip install -r requirements-ui.txt      # ventana de exhibición (PySide6)
pip install -r requirements-voz.txt     # micrófono, reconocimiento y síntesis
python -m hacu.voz --descargar          # voz de Piper, ~110 MB
```

En Linux, `sounddevice` necesita además `PortAudio` del sistema:

```
sudo apt install portaudio19-dev
```

Comprueba que la capa de voz quedó entera, porque instalada a medias no falla al arrancar: degrada en escena.

```
python -m hacu.voz
```

Lista micrófonos y altavoces, y además avisa de las dos ausencias que no impiden arrancar pero se notan con público delante: la voz de Piper sin descargar (Piper arranca un proceso por frase, ~2,5 s contra 0,2 s) y `resemblyzer` sin instalar (HACU no nota cuándo se acerca otra persona).

Detalle completo de la capa de voz en *La capa de voz*.

6. Primer arranque y verificación

```
python run_hacu.py --debug
```

La primera vez descarga el modelo de embeddings (~470 MB) e indexa el corpus: tarda un par de minutos. Las siguientes arrancan directamente.

Solo el primer arranque necesita conexión. Una vez descargados, el embedding del RAG y el modelo de reconocimiento se abren desde la caché local y HACU no vuelve a consultar la red: la sala de la exhibición puede no tener Wi-Fi. Si alguna vez ves que el arranque se queda esperando a huggingface.co, es que algo no está en la caché — no que el sistema necesite internet para funcionar.

Lo que tiene que aparecer, en este orden:

```
--- DIAGNOSTICO DE HARDWARE ---
[OK] GPU detectada: ...
[*] Cargando el modelo en la VRAM...
[*] Sincronizando corpus institucional...
[*] Precalentando el modelo...
[OK] Sistema listo (precalentado en N.Ns).
```

```
--- HACU ---
```

Hola, soy Hacu. Bienvenido a AudacIA. ¿Serías tan amable de decirme cuál es tu nombre?

Verifica que el modelo está de verdad en la GPU, no solo que la GPU existe:

```
python -c "from llama_cpp import llama_supports_gpu_offload as g; print('GPU:', g())"
```

Si imprime False, llama-cpp-python se instaló sin CUDA: vuelve al paso 3 y usa 3b. Con el sistema arrancado, nvidia-smi debe mostrar ~5 GB ocupados y el precalentamiento debe tardar **segundos**, no minutos.

Lista de verificación completa:

```
python -m pruebas.test_unidades      # 742 comprobaciones, ~2 s, sin GPU
python -m pruebas.recuperacion        # calidad del RAG sobre el corpus real
python -m hacu.voz                    # inventario de micrófonos y altavoces
python -m hacu.voz --autopruueba      # circuito de voz completo sin micrófono
```

test_unidades en verde y recuperacion en 39/39 significan que el sistema está sano. Ver *Pruebas*.

7. Arrancar como se arranca el día de la exhibición

```
python run_hacu.py --ui --voz --pantalla-completa
```

Comando	Qué hace
python run_hacu.py	Consola limpia, diagnóstico al log
python run_hacu.py --debug	Router, perfil, latencia y migraciones en pantalla
python run_hacu.py --ui	Ventana de exhibición, sin voz
python run_hacu.py --voz-salida	Consola: escribes tú, HACU responde en voz alta
python run_hacu.py --ui --voz	Ventana con micrófono y altavoz
python run_hacu.py --ui --voz --pantalla-completa	Lo que se proyecta
python -m hacu.voz	Diagnóstico de audio

8. Cuando algo falla

Síntoma	Causa	Qué hacer
ModuleNotFoundError: No module named '...'	Estás usando el Python del sistema, no el del entorno	Activar el entorno. Lo delata el prompt: sin (venv) delante, es el otro Python
No se detecto GPU NVIDIA	nvidia-smi no está en el PATH	Reinstalar el controlador
Arranca pero va lentísimo	llama-cpp-python sin CUDA	Paso 3b
ConfiguracionInviabile: El prompt estimado...	El presupuesto no cabe en n_ctx	Bajar HACU_FRAGMENTOS, o subir HACU_CTX
ConfiguracionInviabile: El embedding multilingue no esta disponible	Falta sentence-transformers, o no está descargado y no hay conexión	Reinstalarlo; con red, el primer arranque lo baja. HACU_MULTILINGUE=0 acepta el modo degradado a sabiendas
getaddrinfo failed hacia huggingface.co en el arranque	Sin DNS, y el modelo no está en la caché	Conectar una vez para descargarlo; después ya no hace falta
Falta la interfaz grafica	Sin PySide6	pip install -r requirements-ui.txt
[mic] Oido: NO disponible	Sin micrófono o sin sounddevice	python -m hacu.voz; ver La capa de voz
Pausas larguísimas entre frases	La voz de Piper no está en models/voz/, así que arranca un proceso por frase (~2,5 s contra 0,2 s)	python -m hacu.voz --descargar

Síntoma	Causa	Qué hacer
Falta resemblyzer para distinguir voces	La capa de voz está instalada a medias	<code>pip install -r requirements-voz.txt</code> . Si <code>webrtcvad</code> no compila en Windows, arranca con <code>HACU_HABLANTES=0</code> y sigue sin esa función
CUDA out of memory al cargar Whisper	El STT no cabe junto al Llama	<code>HACU_STT=tiny</code> , o <code>--voz-salida</code>

El log completo queda en `logs/hacu.log`.

GitHub: publicar y replicar el proyecto

Cómo poner HACU en un repositorio y cómo alguien más lo baja y lo pone a funcionar. Pensado para que dentro de un año, con la exhibición montada otra vez, nadie tenga que reconstruir nada de memoria.

Qué NO entra en el repositorio, y por qué

Un repositorio de Git guarda **todas** las versiones de todo lo que entra. Un archivo de 5 GB añadido y borrado sigue pesando 5 GB en el historial, para siempre, para todo el que clone. GitHub además rechaza archivos de más de 100 MB.

Se queda fuera	Peso	De dónde sale
<code>models/*.gguf</code>	~4,9 GB	Se descarga de Hugging Face (<i>4. El modelo</i>)
<code>models/voz/</code> <code>chroma_db/</code>	~110 MB por voz ~decenas de MB	<code>python -m hacu.voz --descargar</code> Se reconstruye sola desde <code>documents/</code> al arrancar
<code>hacu_memory.db</code>	variable	Datos personales de visitantes. Nunca al repositorio
<code>logs/</code>	crece sin techo	Se abre uno nuevo en cada arranque
<code>pruebas/informes/</code>	~1 MB por corrida	Miden una versión concreta del corpus: envejecen mal
<code>venv/, __pycache__/, *.wav</code>	—	Basura de ejecución

Todo eso ya está en `.gitignore`. No lo quites.

Git LFS no es la solución para el modelo. LFS mueve el peso a otro almacén, pero sigue siendo peso, y la cuota gratuita de GitHub se mide en gigabytes de almacenamiento y de tráfico al mes: un puñado de clones de un `.gguf` de 4,9 GB la agota. El modelo es un artefacto público con URL propia: se descarga, no se versiona.

Lo que **sí** entra: el código, el corpus de `documents/` (son 60 KB de Markdown y son el conocimiento de HACU), las pruebas, las herramientas y esta documentación.

A. Publicar el proyecto por primera vez

A.1 Comprobar que no hay nada que no deba subir

```
cd D:\Proyectos\voz-rag-universidad

python -m herramientas.limpiar          # lista lo prescindible; con --aplicar lo borra
git status --short
git status --ignored --short             # confirma que el modelo y la memoria salen como
↪ ignorados
```

Antes del primer commit, revisa el tamaño de lo que va a entrar:

```
git add -A
git status --short | Measure-Object -Line
git ls-files -s | ForEach-Object { ($_ -split "\t")[1] } |
  ForEach-Object { Get-Item $_ } | Sort-Object Length -Descending |
  Select-Object -First 10 Length, Name
```

Si en esa lista aparece algo de más de un megabyte que no sea un .md del corpus, **para y averigua qué es** antes de seguir.

A.2 Inicializar y primer commit

Si el repositorio ya existe (hay carpeta .git), salta a A.3.

```
git init
git branch -M main
git add -A
git commit -m "HACU: asistente expositor de AudacIA"
```

.gitattributes fuerza finales de línea LF dentro del repositorio. Sin eso, un checkout en Windows escribe CRLF y el mismo árbol clonado en Linux o construido en el contenedor difiere del original, y git diff marca archivos enteros como cambiados sin que nadie los haya tocado.

A.3 Crear el repositorio remoto

Con la línea de órdenes de GitHub (gh, <https://cli.github.com>):

```
gh auth login
gh repo create voz-rag-universidad --private --source . --remote origin --push
```

O a mano: crear el repositorio **vacío** en <https://github.com/new> (sin README, sin .gitignore, sin licencia — los tiene ya el proyecto) y después:

```
git remote add origin https://github.com/<usuario>/voz-rag-universidad.git
git push -u origin main
```

Privado o público. El corpus describe proyectos de investigación de la Universidad Simón Bolívar, con nombres de personas, patentes y aliados. Que eso se publique no es una decisión técnica: consúltalo con el centro antes de poner el repositorio en público. Con `--private` siempre se puede abrir después; al revés no.

A.4 Marcar la versión que se exhibió

Cuando una versión se lleva a una exhibición, ponle una etiqueta. Es lo que permite volver exactamente a lo que funcionó ese día:

```
git tag -a exhibicion-2026-09 -m "Versión llevada a la exhibición de septiembre"
git push origin exhibicion-2026-09
```

B. Replicar el proyecto en otra máquina

Los pasos completos, desde un equipo que no tiene nada.

```
# 1. El código
git clone https://github.com/<usuario>/voz-rag-universidad.git
cd voz-rag-universidad

# 2. El entorno
python -m venv venv
.\venv\Scripts\Activate.ps1
pip install -r requirements.txt
pip install llama-cpp-python --prefer-binary \
  --extra-index-url https://abetlen.github.io/llama-cpp-python/whl/cu121

# 3. El modelo (~4,9 GB; no viene en el repositorio)
#   Ver instalacion.md, paso 4
#   -> models/Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf

# 4. Los extras
pip install -r requirements-ui.txt
pip install -r requirements-voz.txt
python -m hacu.voz --descargar

# 5. Comprobar antes de confiar
python -m pruebas.test_unidades
python run_hacu.py --debug
```

El índice vectorial **no se clona y no hace falta clonarlo**: bootstrap.py lo reconstruye desde documents/ en el primer arranque, y en los siguientes solo sincroniza lo que haya cambiado. Un chroma_db/ copiado de otra máquina, con otra versión de ChromaDB, es una fuente de problemas y no ahorra nada.

Detalle de cada paso y qué hacer cuando falla: *Instalación desde cero*.

C. Trabajar en el proyecto

Ritmo de trabajo

```
git switch -c voz/callar-a-mitad-de-frase    # una rama por cambio
# ... trabajar ...
python -m pruebas.test_unidades             # NO se comitea en rojo
git add -A
git commit -m "La orden de llamar corta a mitad de frase, no en el siguiente punto"
git push -u origin voz/callar-a-mitad-de-frase
gh pr create --fill
```

python -m pruebas.test_unidades tarda dos segundos y no necesita GPU: no hay excusa para saltárselo. Las 742 comprobaciones existen porque cada una cubre algo que se rompió de verdad alguna vez.

Mensajes de commit

Describen **qué cambia de comportamiento**, no qué archivo se tocó. «Arreglos varios» no le sirve a nadie dentro de seis meses; «El índice se carga, no se busca: buscarlo devolvía 5 proyectos de 32» sí.

Cuando cambia el corpus

documents/ no se edita a mano: se regenera desde los informes en Word (ver *El corpus: lo que HACU sabe*). Después de regenerar, **medir siempre** antes de comitear:

```
python -m pruebas.recuperacion --n 6 --detalle
```

Ganchos de pre-commit (opcional pero recomendado)

Un gancho que corra la suite antes de cada commit evita el commit en rojo:

```
# .git/hooks/pre-commit (chmod +x; no se versiona: es local a cada clon)
#!/bin/sh
python -m pruebas.test_unidades || exit 1
```

Integración continua

pruebas/test_unidades.py corre sin GPU, sin red y sin tarjeta de sonido — está escrito así a propósito, y el bloque de la interfaz usa el backend offscreen de Qt. Eso lo hace apto para GitHub Actions tal cual. Guarda esto como .github/workflows/pruebas.yml:

```
name: pruebas
on: [push, pull_request]
jobs:
  unidades:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - uses: actions/setup-python@v5
        with: {python-version: "3.11"}
      - run: pip install langchain-text-splitters numpy PySide6
      - run: python -m pruebas.test_unidades
    env:
      QT_QPA_PLATFORM: offscreen
```

Nota: el flujo **no** instala requirements.txt, y es a propósito. La suite no necesita llama-cpp-python ni ChromaDB: los bloques que los usarían trabajan con dobles, y esas dos librerías se importan de forma perezosa. Las tres del pip install son las únicas que se importan a nivel de módulo en el camino de las pruebas. La suite omite el bloque que no puede correr en vez de fallar, así que la cuenta depende de lo instalado. Medido en entornos limpios: **742/742** con todo, **741/741** con esas tres (sin ChromaDB no corre una comprobación de red), **710/710** sin PySide6 pero con ChromaDB,

y 709/709 sin ninguna de las dos —que es el caso del flujo—. Si en el futuro un bloque nuevo importa el motor real, habrá que añadir la instalación y el flujo pasará de segundos a minutos.

D. Problemas típicos

Síntoma	Qué pasa	Solución
remote: error: File ... is 4.90 GB; this exceeds GitHub's file size limit	El modelo entró al commit	<code>git rm --cached models/*.gguf</code> , confirmar <code>.gitignore</code> , rehacer el commit
El modelo entró en un commit antiguo	Sigue en el historial aunque ya no esté en el árbol	Reescribir con <code>git filter-repo</code> , o empezar un repositorio limpio si aún no lo ha clonado nadie
<code>git diff</code> marca archivos enteros sin haberlos tocado	Finales de línea	<code>git add --renormalize .</code> una vez; <code>.gitattributes</code> evita que vuelva a pasar
Un clon nuevo no arranca	Falta el modelo, o las voces	Son descargas aparte: pasos 3 y 4 de la sección B
<code>hacu_memory.db</code> aparece en <code>git status</code>	Alguien lo añadió con <code>-f</code> , o el <code>.gitignore</code> se editó	<code>git rm --cached hacu_memory.db</code> y revisar quién tiene ya ese commit: son datos de personas

E. Qué revisar antes de hacer público el repositorio

1. `git log --all --stat | Select-String "hacu_memory|\.gguf|\.wav"` — que no haya datos de visitantes ni binarios pesados en **ningún** punto del historial.
2. El corpus de `documents/` lo aprueba el centro, no el repositorio.
3. `logs/` fuera: el log registra las preguntas de los visitantes.
4. Licencia: el proyecto no la declara todavía. Sin archivo `LICENSE`, un repositorio público sigue siendo «todos los derechos reservados» y nadie puede reutilizarlo legalmente — decidir con la universidad si eso es lo que se quiere.

Docker: construir, ejecutar y replicar

El contenedor sirve para **reproducir el entorno del modelo sin pelearse con CUDA en cada máquina**: la imagen trae la cadena de compilación, las dependencias y los embeddings ya descargados. Es la vía cómoda para levantar HACU en un servidor, en otra portátil o en la máquina de un compañero.

Lo que el contenedor NO da. La imagen instala solo `requirements.txt`: no lleva PySide6 ni la capa de voz, y un contenedor no tiene ni pantalla ni tarjeta de sonido del anfitrión. Dentro de Docker, HACU es **consola y texto**. `run_hacu.py --ui` responde [X] Falta la interfaz gráfica y termina. Para la exhibición —ventana, micrófono y altavoz— se usa la instalación nativa de *Instalación desde cero*. Esto no es una carencia que haya que arreglar: exponer audio y GPU a la vez desde un contenedor añade una capa de cosas que pueden fallar el día de la exhibición.

1. Antes de construir

	Windows	Linux
Motor	Docker Desktop con backend WSL 2	Docker Engine
GPU	Controlador NVIDIA con soporte WSL-CUDA	NVIDIA Container Toolkit
Disco	~15 GB para la imagen	ídem

En Linux, sin el Container Toolkit `--gpus all` no existe:

```
sudo apt install -y nvidia-container-toolkit
sudo nvidia-ctk runtime configure --runtime=docker
sudo systemctl restart docker
```

Comprueba que Docker ve la tarjeta **antes** de construir nada:

```
docker run --rm --gpus all nvidia/cuda:12.1.1-base-ubuntu22.04 nvidia-smi
```

Si eso no imprime la tabla de `nvidia-smi`, el problema es del anfitrión y no de HACU. Arréglalo aquí; más adelante solo se vuelve más difícil de diagnosticar.

2. Qué hay dentro de la imagen

Dockerfile, de arriba abajo:

El Dockerfile tiene **dos etapas**: una compila llama-cpp-python contra CUDA y la otra solo ejecuta. La imagen final no lleva nvcc ni el compilador de C++, y eso son unos 3,5 GB menos.

Etapla 1 — constructor (nvidia/cuda:12.8.2-devel-ubuntu22.04)

Capa	Qué hace	Por qué así
Python 3.10 + build-essential, cmake, ninja-build	Toolchain	Compilar llama.cpp
pip wheel --no-binary llama-cpp-python	Construye la rueda con -DGGML_CUDA=on -DCMAKE_CUDA_ARCHITECTURES=\$CUDA_ARCH	--no-binary impide que pip se traiga la rueda de PyPI sin CUDA , que no da error: solo corre en CPU

Etapla 2 — final (nvidia/cuda:12.8.2-runtime-ubuntu22.04)

Capa	Qué hace	Por qué así
Python 3.10 + libgomp1	Runtime mínimo	Sin nvcc: no se compila nada aquí
COPY requirements*.txt → pip install	Dependencias del núcleo	Capa propia, antes del código: cambiar una línea de Python no reinstala ChromaDB
CON_VOZ=1 → libportaudio2, libsndfile1 + requirements-voz.txt	Capa de voz, opcional	pip install sounddevice instala el enlace, no PortAudio; sin la biblioteca del sistema el fallo sale al abrir el micrófono
CON_UI=1 → libs de X + requirements-ui.txt	Ventana, opcional	Qt necesita media docena de bibliotecas que la imagen de CUDA no trae
COPY --from=constructor → pip install de la rueda	Motor del modelo	Ya compilado en la etapa 1
Descarga de paraphrase-multilingual-MiniLM-L12-v2	Embeddings en /opt/hf-cache	Sin esto, cada docker run --rm sin volumen de caché bajaba ~470 MB
COPY . .	El código	Última capa: es lo que más cambia
USER hacu (uid 1000)	No corre como root	Lo que el contenedor escribe en un volumen montado salía con propietario root y después no había quien lo borrara
CMD ["python", "run_hacu.py"]	Consola de HACU	La ventana y la voz no cruzan la frontera del contenedor sin más trabajo

.dockerignore deja fuera models/, chroma_db/, logs/, hacu_memory.db* y los informes de pruebas. La imagen pesa lo que pesan las dependencias, no lo que pesan los datos: el modelo se monta en tiempo de ejecución.

Los cuatro --build-arg

Argumento	Por defecto	Para qué
CUDA_ARCH	120	Arquitectura de la GPU: 120 Blackwell (RTX 50xx), 89 Ada (RTX 40xx), 86 Ampere (RTX 30xx)
RUEDA_CUDA	(vacío)	Con un valor (cu125, cu124...) baja la rueda ya compilada de ese índice en vez de compilar. No sirve para Blackwell : el índice llega hasta cu125
CON_VOZ	0	1 instala micrófono, reconocimiento y síntesis
CON_UI	0	1 instala PySide6 y las bibliotecas de X

3. Construir

```
cd D:\Proyectos\voz-rag-universidad
docker build -t robot-expositor .
```

Eso construye la imagen de consola para Blackwell (RTX 50xx), compilando llama-cpp-python desde el fuente. **La primera construcción tarda entre 30 y 50 minutos**: descarga dos bases de CUDA (varios GB), compila llama.cpp para sm_120, instala PyTorch y baja el modelo de embeddings. Las siguientes reutilizan las capas y, si solo cambió código Python, terminan en segundos.

En una GPU anterior a Blackwell se salta la compilación entera y baja a unos diez minutos:

```
docker build --build-arg RUEDA_CUDA=cu125 --build-arg CUDA_ARCH=89 -t robot-expositor .
```

Con la capa de voz y la ventana dentro (lee antes la sección 4, porque en Windows ni el audio ni la ventana salen del contenedor sin trabajo extra):

```
docker build --build-arg CON_VOZ=1 --build-arg CON_UI=1 -t robot-expositor .
```

El Dockerfile usa RUN --mount=type=cache, que necesita **BuildKit**. Docker Desktop lo trae activado; en un Docker antiguo de Linux, DOCKER_BUILDKIT=1 docker build

4. Ejecutar

Lo más corto es el script que ya está en el proyecto:

```
.\iniciar_robot.ps1
```

Que es exactamente esto:

```
docker run --gpus all -it --rm `
  -v "${PWD}:/app" `
  robot-expositor
```

Parte	Para qué
--gpus all	Expone la GPU. Sin esto, HACU corre en CPU y un turno tarda minutos
-it	Terminal interactiva: HACU es una conversación, necesita entrada
--rm	Borra el contenedor al salir. El estado vive en el volumen, no en el contenedor
-v "\${PWD}:/app"	Monta la carpeta del proyecto completa

Ese único montaje hace todo el trabajo: dentro del contenedor, /app es la carpeta del anfitrión, así que el modelo de models/, el corpus de documents/, el índice chroma_db/ y la memoria hacu_memory.db son los mismos archivos que se ven en Windows. El índice que construye el contenedor queda en el disco del anfitrión y no hay que reconstruirlo en el siguiente arranque.

En Linux el script equivalente es:

```
docker run --gpus all -it --rm -v "${PWD}:/app" robot-expositor
```

Con variables de configuración (*Configuración*):

```
docker run --gpus all -it --rm -v "${PWD}:/app" `
  -e HACU_DEBUG=1 -e HACU_RETENCION=8 `
  robot-expositor
```

Montar solo lo necesario

-v "\${PWD}:/app" monta **todo**, incluido el código: lo que corre es el código del anfitrión, no el que se copió en la imagen. Va muy bien mientras se desarrolla —se edita en Windows y se ejecuta dentro sin reconstruir— pero significa que la imagen no es autosuficiente. Para desplegar de verdad, monta solo los datos y deja que el código venga de la imagen:

```
docker run --gpus all -it --rm \
-v "$PWD/models:/app/models:ro" \
-v "$PWD/documents:/app/documents:ro" \
-v "$PWD/chroma_db:/app/chroma_db" \
-v "$PWD/logs:/app/logs" \
robot-expositor
```

hacu_memory.db queda deliberadamente fuera: sin él, cada arranque empieza sin memoria de visitantes, que es lo correcto en una demostración pública. Si la quieres persistente, monta una carpeta en /app/datos y apunta ahí la memoria con HACU_DB —montar un fichero suelto que todavía no existe hace que Docker cree un directorio con ese nombre, y entonces SQLite no abre nada—:

```
docker run --gpus all -it --rm \
-v "$PWD/models:/app/models:ro" \
-v "$PWD/datos:/app/datos" \
-e HACU_DB=/app/datos/hacu_memory.db \
robot-expositor
```

Lee *Datos de los visitantes* antes: eso guarda en disco lo que dicen los visitantes.

Con Compose

Si prefieres no recordar la orden larga, un docker-compose.yml como este hace lo mismo (no está en el repositorio; créalo si lo quieres):

```

services:
  hacu:
    build: .
    image: robot-expositor
    stdin_open: true
    tty: true
    volumes:
      - ./models:/app/models:ro
      - ./documents:/app/documents:ro
      - ./chroma_db:/app/chroma_db
      - ./logs:/app/logs
    environment:
      HACU_DEBUG: "1"
    deploy:
      resources:
        reservations:
          devices:
            - driver: nvidia
              count: all
              capabilities: [gpu]

```

```
docker compose run --rm hacu
```

5. Verificar que el contenedor usa de verdad la GPU

Que `--gpus all` no proteste no significa que el modelo esté en la tarjeta.

```

docker run --rm --gpus all robot-expositor `
python -c "from llama_cpp import llama_supports_gpu_offload as g; print('GPU:', g())"

```

Tiene que imprimir GPU: True. Y con HACU arrancado, `nvidia-smi` en el anfitrión debe mostrar ~5 GB ocupados y el precalentamiento debe tardar segundos.

Por qué la imagen compila en vez de bajar una rueda

La portátil de la exhibición lleva una RTX 5070 Ti: **Blackwell, sm_120**. Los hechos, comprobados uno a uno:

- El índice de ruedas de `llama-cpp-python` publica hasta **cu125** (cu126 y cu128 devuelven 404). Comprobado el 21/09/2026 contra <https://abetlen.github.io/llama-cpp-python/whl/>.
- CUDA 12.5 **no conoce sm_120**. No solo le falta el código nativo: tampoco genera PTX que el controlador pueda traducir al vuelo, porque esa arquitectura no existía cuando se publicó.

Conclusión: **para una RTX 50 no hay rueda que valga**. Hay que compilar contra CUDA 12.8, que es lo que hace la etapa 1 del `Dockerfile` por defecto. De ahí los 30–50 minutos de la primera construcción.

Para tarjetas anteriores la rueda sí sirve y se ahorra todo eso:

```
docker build --build-arg RUEDA_CUDA=cu125 --build-arg CUDA_ARCH=89 -t robot-expositor .
```

La ruta de Docker **sigue sin verificarse sobre la RTX 5070 Ti de esta máquina**: el desarrollo y todas las medidas del proyecto se hicieron sobre la instalación nativa de Windows. Lo que cambió es que la imagen ya no está construida sobre una versión de CUDA que se sabe incompatible. La comprobación de GPU: True de arriba sigue siendo la que falta.

6. Replicar el proyecto entero con Docker

Desde una máquina que solo tiene Docker y el controlador NVIDIA:

```
# 1. El código
git clone https://github.com/<usuario>/voz-rag-universidad.git
cd voz-rag-universidad

# 2. El modelo (~4,9 GB; no viene en el repositorio ni en la imagen)
mkdir -p models
# Ver instalacion.md, paso 4
# -> models/Meta-Llama-3.1-8B-Instruct-Q4_K_M.gguf

# 3. La imagen
docker build -t robot-expositor .

# 4. Comprobar que la GPU está dentro
docker run --rm --gpus all robot-expositor \
  python -c "from llama_cpp import llama_supports_gpu_offload as g; print('GPU:', g())"

# 5. Comprobar que el sistema está sano (sin GPU, ~2 s)
docker run --rm robot-expositor python -m pruebas.test_unidades

# 6. Arrancar
docker run --gpus all -it --rm -v "$PWD:/app" robot-expositor
```

El paso 5 es barato y vale mucho: si la suite pasa dentro del contenedor, el enrutado, el estilo, la memoria y la profundidad de recuperación están intactos, y cualquier fallo posterior es del modelo o de la GPU, no del código. Serán **710 comprobaciones y no 742**: el bloque de la interfaz se omite solo, porque la imagen por defecto no lleva PySide6 a propósito (con `--build-arg CON_UI=1` pasan las 742).

7. Cuando algo falla

Síntoma	Causa	Solución
could not select device driver "" with capabilities: [[gpu]]	Falta NVIDIA Container Toolkit (Linux) o el backend WSL 2 (Windows)	Sección 1
manifest for nvidia/cuda:12.8.2-... not found	Ese tag ya no se publica	Buscar uno vigente en https://hub.docker.com/r/nvidia/cuda/tags y pasarlo con --build-arg CUDA_VERSION=
the --mount option requires BuildKit	Docker antiguo sin BuildKit	DOCKER_BUILDKIT=1 docker build ...
La construcción se queda media hora en Building wheel for llama-cpp-python	Está compilando para tu GPU	Es lo esperado en Blackwell. En otras tarjetas, --build-arg RUEDA_CUDA=cu125
nvcc fatal: Unsupported gpu architecture 'compute_120'	CUDA_VERSION anterior a 12.8	Dejar el valor por defecto, o subirlo
could not load the Qt platform plugin "xcb"	Imagen construida sin CON_UI=1, o sin servidor X	Sección 2; la ventana va en nativo
PortAudioError: Error querying device -1	Imagen sin CON_VOZ=1, o sin tarjeta de sonido dentro del contenedor	El audio va en nativo
El arranque avisa No se detecto GPU NVIDIA	Falta --gpus all	Añadirlo
No such file or directory: '/app/models/Meta-Llama-...gguf'	El modelo no está montado (.dockerignore lo excluye a propósito)	Montar models/
[X] Falta la interfaz grafica	La imagen no lleva PySide6, y es correcto	La ventana va en nativo
Va lentísimo dentro y rápido fuera	El modelo está en CPU	Sección 5
La construcción tarda muchísimo en sentence-transformers	Está bajando PyTorch (~2 GB)	Normal la primera vez; después se cachea
chroma_db da errores raros tras usarlo desde Windows y desde el contenedor	Versiones distintas de ChromaDB sobre el mismo índice	python -m herramientas.limpiar --aplicar --indice y dejar que se reconstruya

El log del contenedor queda en logs/hacu.log del anfitrión si logs/ está montado.

Arquitectura

Cómo está montado HACU por dentro, qué hace cada pieza y por qué está donde está.


Idea de fondo

Todo corre **en local**: el modelo, el índice vectorial y la memoria de los visitantes no salen de la máquina. No hay llamadas a ninguna API. Eso condiciona cada decisión: la ventana de contexto es un presupuesto fijo, el modelo es un 8B cuantizado con manías conocidas, y no hay un modelo mayor esperando detrás para arreglar lo que salga mal.

De ahí salen las tres reglas que gobiernan el diseño:

1. **Lo determinista se hace en Python, no se le pide al modelo.** Recortar coletillas, filtrar adulación, trocear frases para la voz, decidir qué se recupera: todo eso tiene una implementación exacta y verificable. Al modelo se le pide solo lo que solo él puede hacer.
2. **Nada literal delante del modelo.** Una frase de ejemplo metida en un prompt acaba recitada palabra por palabra. Ha pasado cuatro veces en este proyecto (ver «Contaminación», abajo). Las reglas dicen *qué hacer*, no *qué decir*.
3. **Cada umbral sale de una medida.** No hay ningún número en `config.py` que sea una suposición; al lado de cada uno está qué se midió para elegirlo.
4. **Local quiere decir local también al arrancar.** Las librerías de modelos consultan HuggingFace al abrir un modelo aunque ya esté descargado, y una sala sin Wi-Fi convertía eso en un arranque caído. Tanto el embedding del RAG como el reconocedor piden primero la copia en disco y solo descargan si no la hay.

El recorrido de un turno



Lo que se **lee** en pantalla, lo que se **oye** y lo que se **guarda** son exactamente el mismo texto. Es la razón de que el filtrado de estilo ocurra en el retenedor y no en cada consumidor: si cada uno filtrara por su cuenta, acabarían divergiendo.

Los módulos

Núcleo

Archivo	Responsabilidad
run_hacu.py	Entrada: argumentos, diagnóstico de hardware, elige consola o ventana
hacu/bootstrap.py	<i>Composition root</i> . Construye y cablea todo el árbol una sola vez
hacu/config.py	Toda la configuración, con la justificación de cada valor
hacu/session.py	Orquestación de un turno. La consola, la ventana y las pruebas usan este mismo camino
hacu/llm.py	Único acceso a llama.cpp, serializado. Decodificación restringida a JSON para los prompts de utilidad

Archivo	Responsabilidad
hacu/prompts.py	System prompt, perfiles de audiencia, saludo de apertura y prompts de utilidad

Conocimiento

Archivo	Responsabilidad
hacu/routing.py	Enrutado léxico: a qué corpus va la pregunta. Aprende los nombres de proyecto del índice al arrancar
hacu/context.py	Qué se le manda al modelo: política de profundidad, anclaje de seguimientos, notas privadas
hacu/rag.py	Indexación por secciones ## y recuperación sobre ChromaDB
hacu/lexico.py	Rescate por palabra rara: lo que el embedding no encuentra pero está escrito

Memoria

Archivo	Responsabilidad
hacu/identity.py	Quién es el visitante: valida nombres, migra perfiles
hacu/memory.py	Persistencia en SQLite: historial y hechos
hacu/extractor.py	Extrae hechos de lo que dice el visitante, en un hilo aparte
hacu/sanitizer.py	Qué merece guardarse como hecho y qué no

Salida

Archivo	Responsabilidad
hacu/estilo.py	Recorte determinista: coetillas, adulación, fugas del andamiaje
hacu/cuidado.py	Qué hacer cuando el visitante no viene a preguntar por proyectos
hacu/cli.py	Consola del operador
hacu/interfaz/	Ventana de exhibición (<i>La ventana de exhibición</i>)
hacu/voz/	Oído y boca (<i>La capa de voz</i>)

Alrededor

Carpeta	Contenido
documents/	El corpus en dos niveles (<i>El corpus: lo que HACU sabe</i>)
herramientas/	Generación del corpus desde los informes en Word, y limpieza del árbol
pruebas/	Suite de regresión y herramientas de medición (<i>Pruebas</i>)
docs/	Esta documentación

Enrutado: tres dominios, uno heredado

routing.py clasifica cada mensaje en AUDACIA, UNIVERSIDAD o GENERAL con patrones léxicos, no con un modelo: son microsegundos y es auditable.

Al arrancar, bootstrap.py le enseña al router **los nombres de los 32 proyectos**, leídos del índice-catálogo. Sin eso, «cuéntame de Holosand» caía en GENERAL y se saltaba toda la política de profundidad.

Un mensaje que el router no reconoce pero que se apoya en lo anterior —«¿y eso para qué sirve?», «cuéntame más», o cualquier frase que empiece por «y»— **hereda el dominio del último turno que sí lo tuvo**. Es más fiable que dejárselo a la distancia semántica, que no sabe de qué se venía hablando.

La excepción: las preguntas sobre HACU mismo («¿y a ti qué te gusta?») **no** heredan. Si heredaran, una pregunta personal arrastraría documentación de Audacia y HACU contestaría con un proyecto.

Profundidad: la pregunta decide cuánto se trae

Con 32 proyectos, una sola forma de recuperar no sirve. context.py clasifica en cuatro niveles, y cada uno recupera algo distinto:

Nivel	Qué lo dispara	Qué recupera
CATALOGO	«¿qué proyectos tienen?»	el índice entero, cargado tal cual
RESUMEN	«explícame cada proyecto»	el índice como esqueleto + fichas
DETALLE	«cuéntame todo sobre Mary»	fichas, sin filtro
CENTRO	«¿qué patentes tiene el centro?»	solo lo institucional

Invariante: el índice se carga, no se busca. Queda excluido de toda búsqueda por similitud, por dos motivos medidos:

- Buscarlo devolvía 2 de sus 6 fragmentos, así que HACU enumeraba 5 proyectos de 32 y creía que esos eran todos.

- Al revés: siendo un documento genérico que menciona todo, ganaba consultas que no eran suyas. A «¿cuántos estudiantes hay?» le llegó el catálogo y HACU respondió «32 proyectos» — un número de otra pregunta — en vez de admitir que no tenía el dato.

Y lo que el embedding pierde, lo rescata la palabra. Medido: a «¿cuál sería el proyecto más interesante para los conductores?» no volvía la ficha de Detección de Fatiga Visual, que dice literalmente «conductores»; ganaba el Proyecto Tanque, porque un dron terrestre está semánticamente más cerca de «conducir vehículos» que una ficha sobre párpados. Un embedding de paráfrasis mide parecido global y una palabra rara dentro de una ficha larga se diluye — pero esa palabra rara es la señal más fuerte que hay.

hacu/lexico.py mantiene un índice invertido en memoria sobre lo que Chroma tiene indexado, y rescata las piezas que comparten con la pregunta una palabra **distintiva**: una que aparece en pocas piezas del corpus. La rareza se mide sobre el propio corpus y no se lista a mano — «proyecto» sale en casi todas y no distingue nada; «conductor» sale en dos y lo distingue todo.

El rescate **sustituye**, no añade: entra la rescatada y sale el peor vecino semántico. Así el número de fragmentos no cambia y el presupuesto de contexto sigue siendo el que se verifica al arrancar. Medido sobre las 39 consultas, con el rescate desactivado y reactivado en la misma corrida: **39/39 con el embedding multilingüe** (36/39 sin el rescate) y **38/39 con el embedding en inglés** (25/39 sin él) — una coincidencia literal no depende del idioma del embedding, así que el modo degradado deja de ser tan malo.

El nivel CENTRO0 existe por otra medida: el corpus de AudacIA son 37 fragmentos de fichas contra 10 institucionales, y sin filtrar, «¿qué patentes tiene el centro?» recuperaba cuatro proyectos de salud y ni una patente.

El presupuesto de contexto

La ventana son 16 384 tokens. config.py estima el peor caso —system prompt + fragmentos + hechos + historial— y bootstrap.verificar_presupuesto() **aborta el arranque** si no cabe.

No es exceso de celo. Cuando el contexto se desborda, llama.cpp descarta por la izquierda, y lo primero que se pierde es el system prompt: HACU cambiaría de personalidad a mitad de exhibición sin que nada lo indicara. Es mejor no arrancar.

```
python -c "from hacu.config import AppConfig; print(AppConfig().presupuesto_contexto())"
```

Actualmente: **10 274 de 15 484 tokens**.

Cuando el visitante no pregunta nada

Tres fallos medidos en la sesión con público del 21/09/2026, y las tres capas deterministas que los cierran. Los tres salían del mismo sitio: el sistema trataba cualquier turno como una pregunta que había que contestar largo.

1. El cierre largo se colaba

`es_despedida()` tenía un tope de 12 palabras para no confundir «Muchas gracias, ahora explícame el Tanque» con una despedida. El efecto era el contrario del buscado: los cierres que más daño hacen son largos.

«Wow, suena muy impresionante... Definitivamente si tengo alguna curiosidad adicional te la haré saber. Por ahora, gracias por compartir toda esa información.» — 60 palabras, ninguna pregunta, cuatro párrafos de respuesta.

Ahora no hay tope de palabras. Lo que distingue a una petición es **la posición**: un verbo de petición que abre una oración, o un signo de interrogación. «Es genial ver *cómo* están aplicando la IA» lleva «cómo» y no pregunta nada, y antes bastaba esa palabra suelta para descartar el turno como no-social.

2. El techo de tokens no distinguía

Había dos niveles: 384 normal y 900 extenso. Un agradecimiento se llevaba 384 y el modelo los llenaba —cuatro turnos de esa sesión tocaron el techo con `extenso=False`, según `logs/hacu.log`—. Ahora son tres (`llm.Aliento`):

Nivel	Tokens	Cuándo
BREVE	116	No piden nada, solo acusan recibo, o piden un dato
NORMAL	384	El caso corriente de tarima
EXTENSO	900	Piden desarrollo, o el catálogo entero

El nivel lo decide lo que el turno PIDE, no lo largo que venga. Hay preguntas de tres palabras que necesitan seis frases («¿y Orion?») y párrafos enteros de agradecimiento que se contestan con una.

BREVE reconocía 3 turnos de 51

La primera versión ataba BREVE a los turnos sociales. El guion marca **51 de 100 turnos** como breves y el runtime reconocía 3: los otros 48 recibían 384 tokens —unos 1.400 caracteres— y el modelo los usaba. En la cuarta corrida, siete turnos fallaron solo por longitud.

`routing.aire_breve()` amplía el reconocimiento a tres formas de no pedir desarrollo, y ninguna es la longitud del mensaje:

1. **No pide nada.** Un cierre, un elogio, una afirmación sobre uno mismo o una negativa («no me interesan los robots»). Reutiliza `pide_algo()`, que ya distinguía posición de palabra suelta.
2. **Solo acusa recibo.** «Ajá», «mmm», «ah, ahora sí».
3. **Pide un dato.** `pide_un_dato()` mira el texto **con tilde**, porque en castellano la tilde es justo lo que separa el interrogativo del relativo: «¿QUÉ sensor usa?» pide un dato y «tengo entendido QUE vuela» no pregunta nada. Y tras «qué», un **verbo** abre explicación («¿qué

hace Neupeek?») mientras que un **sustantivo** pide un valor (*«¿qué sensor usa?»*). Si el visitante escribe sin tildes no se detecta y el turno cae en **NORMAL**, que es el lado seguro; el dictado de voz, que es la entrada real de la tarima, sí las pone.

El orden importa: **fondo > brevedad > anchura**. Pedir detalle manda sobre todo; la brevedad manda sobre el catálogo, porque *«¿cuántos proyectos tiene?»* necesita el índice entero para contar pero se responde con un número.

Los 116 tokens no son un redondeo. En la corrida del 21/09 un turno se cortó en 384 tokens y entregó 1.379 caracteres: **3,59 caracteres por token**. El guion exige 420 caracteres en los turnos breves —unos 25 segundos hablados, que en una sala ya es largo— y $420/3,59 = 117$.

Medido sobre las respuestas reales de esa corrida, aplicando el techo a lo que `aire_breve` detecta y recortando por frase completa: **+5 turnos correctos y ninguno roto**. Es la simulación conservadora —recorta lo que el modelo ya escribió, sin suponer que un techo más bajo le haga escribir mejor—, así que el efecto real no debería ser peor. Leídos uno a uno, los recortes no pierden nada: la explicación de la neumonía sigue entera en 340 caracteres de 715, y el desmentido del observatorio en 369 de 574.

El techo es la red, no el objetivo: una respuesta que nace larga y se corta pierde el final. Por eso hay además una nota de turno que le pide contestar en una o dos frases, para que nazca del tamaño que toca.

Queda fuera una cuarta forma: la **evasiva de fuera de dominio** (*«¿sabes cómo se hace el arroz de lisa?»*). `fuera_de_la_exhibicion()` necesita el material recuperado y se calcula en `ContextBuilder`, no en `HacuSession`, que es donde se elige el aliento. Cuesta un turno del guion (G59) y se deja así antes que pasar estado entre las dos capas.

3. Le ponía palabras en la boca al visitante

El peor de los tres. Al rellenar esos párrafos, HACU le contaba al visitante lo que el visitante supuestamente había dicho — y se lo inventaba:

«Me parece que has mencionado varios proyectos que te han llamado la atención, incluyendo el proyecto Mario, el ROV Submarino y Solenium.»

El visitante no nombró ninguno de los tres. Es el contexto recuperado leído como si lo hubiera dicho la persona de enfrente. Aparece siete veces en esa transcripción y las siete son falsas.

`estilo.filtrar_atribuciones()` borra la frase entera. Solo caza las metaobservaciones sobre lo que el visitante mencionó o entendió: **«me dijiste que estudias Sistemas» no está en la lista a propósito**, porque eso es seguir el hilo, que es justo lo que se quiere.

El guardarraíl se disparaba en los seguimientos

Medido en la corrida de 100 turnos del 21/09: `fuera_de_la_exhibicion()` daba `True` para **«Ajá.»**, **«Mmm.»**, **«¿En serio?»**, **«Ah, ahora sí.»**. Un acuse de recibo clasifica como **GENERAL** y no recupera contexto, que era exactamente la condición del aviso.

Con *«estás fuera de tu terreno»* en las notas del turno, HACU hacía una de dos:

- abandonaba — «estamos fuera de mi área de conocimiento», a un «¿En serio?» sobre el dron del que acababa de hablar;
- o se inventaba un tema — un «Ajá.» lo mandó a explicar Vallenato Master.

Cuatro turnos así en una sola corrida. Un acuse de recibo **no tiene tema propio**: se refiere a lo último que dijo HACU, así que no puede estar fuera de dominio. `routing.es_acuse_de_recibo()` los reconoce —todas las palabras de acuse o relleno, al menos una de acuse, máximo cinco— y, junto con `es_seguimiento()`, quedan excluidos del aviso.

El agujero no es una puerta: «¿Qué hora es?» tiene cuatro palabras y sigue siendo fuera de dominio, porque tiene tema propio.

«No tengo información sobre MacondoLab» (y sí la tenía)

Falló en **las tres corridas** de 100 turnos, que es lo que lo separa del ruido. La causa no era el modelo. Para «¿Qué es MacondoLab?» el embedding devolvía seis fragmentos —Vallenato Master, Neupeek, Camille, dos cabeceras de área...— y **ninguno nombraba MacondoLab**. HACU contestaba correctamente ante un contexto que no traía el dato.

MacondoLab vivía en dos piezas del corpus y no tenía sección propia: aparecía como una línea dentro de `## Personas del centro`, entre seis biografías. Un embedding de «¿Qué es MacondoLab?» no se parece a un bloque de currículos.

El rescate léxico existe justo para esto —una palabra rara que nombra su objetivo— pero **solo corría en buscar, no en buscar_relevante**, que es la ruta de las preguntas que el router clasifica como GENERAL. Y «¿Qué es MacondoLab?» clasifica GENERAL.

Por qué no basta con la rareza. Medido sobre el corpus real: `macondolab` aparece en 2 piezas y anos en 1. La palabra más rara es la que no nombra nada, así que un umbral de frecuencia no las separa — y rescatar por «años» metería la ficha de Mary en un «¿cuántos años tienes?», y con ella desactivaría el aviso de fuera-de-dominio, que se apaga en cuanto hay contexto recuperado.

Lo que sí las separa es la **mayúscula que no abre oración**: `lexico.nombres_propios()`. En la ruta GENERAL el rescate exige nombre propio, no solo rareza. Medido después del cambio: las dos preguntas por MacondoLab recuperan las piezas que lo nombran, y «¿cuántos años tienes?» y «cuéntame un chiste» siguen sin recuperar nada. `pruebas/recuperacion.py` sigue en 39/39 multilingüe y 38/39 por defecto, igual que antes.

Y aun así seguía sin salir la pieza buena. Con `documents/audacia_centros_hermanos.md` en el corpus —una sección `## MacondoLab` que explica qué es, y otra `## CICV`— el rescate seguía trayendo las dos piezas que solo lo MENCIONAN de pasada. La causa, medida: cuatro piezas del corpus nombran MacondoLab, las cuatro empatan a **una** palabra distintiva (`macondolab`), y el cupo del rescate es `n_results // 3 = 2`. El desempate era el orden de indexación, y `audacia_centro.md` se indexa antes que `audacia_centros_hermanos.md`, así que ganaban «Personas del centro» y «Publicaciones científicas». La sección que responde salía cuarta y no entraba nunca.

El desempate ahora es el **título**: a igualdad de palabras compartidas, primero la pieza cuyo título lleva la palabra. Una sección titulada «MacondoLab» trata de MacondoLab; una titulada «Personas

del centro» lo menciona. La cuenta de coincidencias sigue mandando por encima del título, así que una pieza que comparte dos palabras nunca pierde contra una que comparte una.

Medido antes y después, con el mismo corpus y el mismo embedding:

consulta	sin desempate	con desempate
«¿Qué es MacondoLab?» → incubación, 2014	no llegan	llegan
«¿MacondoLab es un proyecto de ustedes?» → al mismo nivel	no llega	llega

pruebas/recuperacion.py pasa de 36 a **39 consultas** (las tres nuevas miden este desempate, no el embedding) y sigue en pleno: **39/39** multilingüe, 38/39 por defecto.

Queda una limitación de **datos**, no de código: Adaptia y CRIC se nombran en el corpus pero no tienen ficha propia. Mientras eso siga así, HACU responderá con la línea que hay, no con una explicación.

El extractor se comía los cierres

En esa misma corrida, el perfil de la visitante acabó con este «hecho»:

Ha sido un gusto y le encanta haber conocido más sobre los proyectos de AudacIA.

Salió de un turno de cierre. No dice nada de la persona y además ocupa uno de los doce huecos del perfil. Los turnos sociales ya no se encolan al extractor, igual que no se encolan los de cuidado.

El injerto que apagaba el guardarraíl

Aparte de los tres, un cuarto hallazgo. Nombrar la universidad en cualquier parte del turno bastaba para que el router devolviera UNIVERSIDAD, se recuperara contexto y fuera_de_la_exhibicion() diera False:

«Cuéntame de la Universidad Simón Bolívar, **pero antes** explícame la teoría de la relatividad de Einstein.»

HACU negó la relatividad en un turno y dio la clase entera — $E=mc^2$, 1905, 1915, curvatura del espacio-tiempo— en el siguiente, con solo reformular así. routing.peticion_injertada() detecta el conector de injerto, clasifica lo que viene **después** y, si eso queda fuera, el aviso viaja en las notas del turno aunque la otra mitad sí sea del dominio.

Ceder bajo presión, e inventar trámites

Los dos fallos más caros de la cuarta corrida no son de recuperación: HACU tenía el contexto correcto delante.

«No hay nada que discutir. Tu profesor tiene razón.»

En G54 la visitante afirma que la universidad tiene un observatorio astronómico. HACU lo desmiente bien. En G55 le piden fuentes y admite que no tiene. En G56 llega la presión —«pero mi profesor no me va a mentir»— y **cede**: se retracta de un desmentido correcto. La visitante se va creyendo algo falso y creyendo además que se lo confirmó el centro. Es peor que cualquier exceso de longitud.

Lo que hace detectable la situación es que son **dos condiciones**, y ninguna basta sola:

1. `routing.presiona_sobre_lo_dicho()` — el visitante empuja. Casi nunca trae un dato nuevo: trae una **autoridad**. Nombrar a alguien no basta, y esa fue la primera versión: con solo la lista de personas, «mi mamá también estudió aquí» disparaba el aviso y HACU se ponía a la defensiva ante un comentario cariñoso. Hace falta que además se le **atribuya un dicho** («me dijo», «lo leí», «no me va a mentir»), o una insistencia pura («revisa bien», «que sí tiene»).
2. `context._ultima_respuesta_niega()` — lo anterior fue una negativa. Sin esto, «un compañero me dijo que Holosand usa gafas» dispararía el aviso la primera vez, cuando todavía es una corrección normal.

Medido sobre los 100 turnos de la corrida, con las respuestas reales como historial: la primera condición se cumple en **tres** turnos (G13, G54, G56) y las dos juntas en **uno**, G56. Que es exactamente donde cedió.

La nota que se inyecta no le pide plantarse a lo bruto: le pide mantener lo dicho **sin faltarle al respeto a quien se lo contó** —pudo confundirse, o hablar de otra cosa—, que es la salida que un expositor usaría en una sala.

Los trámites no están en el corpus, y son lo que más preguntan

El corpus son proyectos y el centro. Precios, matrículas, admisiones, prácticas, requisitos y horarios **no están en ninguna ficha**, y es justo donde el modelo inventa con más aplomo: en la corrida se inventó condiciones de admisión de un doctorado (G53) y a quién escribir para hacer prácticas (G94).

`routing.pregunta_por_tramite()` reconoce la categoría entera en vez de ir turno a turno. Sobre los 100 del guion dispara en **tres** —G35, G53, G94— y en ningún otro: «¿cuántos metros cuadrados tiene el centro?» es una cifra del corpus, no un trámite. La nota le dice que ese dato no lo tiene y que remita a la universidad, y le deja dar un correo o un teléfono **si están en las notas** —el de Audacia sí lo está— porque lo prohibido es inventarse el procedimiento, no dar un contacto documentado.

Ninguna de las dos se puede medir sin GPU: las notas cambian lo que el modelo escribe, no lo que se recupera. Lo que sí está medido, y es lo que evita el falso positivo caro, es **cuándo disparan**.

Contaminación: la regla que más veces se ha roto

Un modelo de 8B copia cualquier cadena literal que se le ponga delante.

Ha ocurrido cuatro veces en este proyecto, siempre igual: un texto de andamiaje —un ejemplo dentro de un prompt, una nota de contexto, un saludo dictado— aparece literal en la respuesta al

visitante.

Qué se puso delante	Qué recitó HACU
Un ejemplo con «Windows 11» en el prompt de extracción	«Windows 11» en la conversación
Una frase de perfil entera como ejemplo	La frase entera
La nota Recuperado de la documentacion institucional de la Universidad Simon Bolivar:	La frase, verbatim, en 11 de 30 turnos
La regla 10 decía «pregúntale qué le trae a la exhibición»	Esa pregunta exacta, ignorando lo que el visitante acababa de contar

Las defensas, en capas:

1. **Los prompts dicen qué hacer, no qué decir.** Las notas privadas se titulan «Lo que sabes de AudacIA», no con el nombre de ningún documento.
2. **El saludo de apertura no pasa por el modelo.** Es texto fijo que `session.saludar()` escribe directamente y registra en el historial.
3. **pruebas/test_unidades.py lo comprueba.** El bloque prompts verifica que el system prompt no nombra ningún proyecto del corpus; el bloque saludo, que el saludo no está dentro del system prompt.
4. **estilo.limpiar_fugas()** borra en tiempo de ejecución lo que se cuele igual.

Concurrencia

Hilo	Qué hace
Principal	Consola, o bucle de eventos de Qt
TrabajadorTurno	Generación del turno, fuera del hilo de Qt
TrabajadorTranscripcion	Reconocimiento de voz
TrabajadorEscuchaContinua	Escucha automática, cuando está activa
Locutor / TTS	Síntesis y reproducción, con su propia cola
BackgroundMemoryExtractor	Extracción de hechos, después del turno

`llm.py` **serializa** todo acceso a `llama.cpp` con un cerrojo: el modelo es uno y no es reentrante, y el extractor de memoria compite con el turno del visitante por él. El cierre (`bootstrap.cerrar`) drena la cola del extractor antes de soltar la base de datos y la VRAM, para no perder hechos a medio escribir.

Ese cerrojo es el único punto de serialización real del sistema: los hilos son concurrentes en Python, pero la GPU atiende de uno en uno. Mientras el extractor resuelve sus 96 tokens, el siguiente turno del visitante espera.

El presupuesto de VRAM

Aritmética sobre la arquitectura de Llama-3.1-8B (32 capas, 8 cabezas KV, head_dim 128) y el n_ctx de config.py. No es una medición: para medirlo de verdad, nvidia-smi con HACU arrancado, o verbose=True en ModelConfig.

Partida	GiB
Pesos Q4_K_M	4,58
Caché KV fp16 con n_ctx=16384 (128 KiB por token)	2,00
Buffer de cómputo (n_batch=512)	~0,60
faster-whisper small int8 en CUDA	~0,50
Total	~7,7 de 12

Quedan unos 4,3 GiB libres. **HACU no está limitado por VRAM**, y por eso mover capas a la RAM del sistema (n_gpu_layers menor que -1) solo puede empeorarlo: cada token que pasa por una capa en CPU cruza el bus PCIe dos veces. Esa opción existe para máquinas donde el modelo no cabe, no para ganar calidad.

Donde la RAM y la CPU **sí** tienen sentido es fuera del camino crítico: el sintetizador ya corre en CPU a propósito (SintetizadorPiperEnProceso, 0,21 s por frase) justo para no tocar la VRAM que necesitan el modelo y el reconocedor.

La caché KV es la palanca, no los pesos

La caché crece **linealmente** con n_ctx, y es lo que decide cuánto contexto cabe. Cuantizarla a 8 bits (type_k/type_v = q8_0) la parte por la mitad con la menor pérdida de calidad de todas las cuantizaciones posibles:

n_ctx	KV fp16	KV 8 bits	Total con el modelo de hoy
16 384	2,00 GiB	1,00 GiB	7,68 → 6,68 GiB
32 768	4,00 GiB	2,00 GiB	9,68 → 7,68 GiB

Se activa con HACU_KV8=1. Si la versión instalada de llama-cpp-python no admite type_k/type_v, HACU **arranca igual en fp16 y lo avisa en el log**: no se puede quedar una exhibición sin arrancar por una opción de afinado.

herramientas/presupuesto_vram.py hace esta cuenta para cualquier combinación de modelo, contexto y cuantización, antes de bajarse nueve gigas:

```
python -m herramientas.presupuesto_vram --todos --kv8
```

Y cruza el resultado con el presupuesto de contexto: por debajo de **13 312 tokens** de n_ctx, verificar_presupuesto aborta el arranque. Las filas que entran en la VRAM pero no llegan a ese mínimo salen marcadas, porque son las que más engañan — un modelo grande con poco contexto entra de sobra en la tarjeta y no sirve.

Subir n_ctx a secas no cambia nada

El error simétrico del anterior, y más fácil de cometer. El tamaño del prompt lo fijan el **historial** y los **fragmentos recuperados**, no la ventana. Doblar n_ctx de 16 384 a 32 768 sin tocar nada más deja esto:

	prompt	disponible	holgura
n_ctx 16 384	12 004	15 484	3 480
n_ctx 32 768	12 004	31 868	19 864 sin usar

El prompt es idéntico. Lo único que cambia es la holgura, y la holgura no responde preguntas. Para que el contexto extra sirva hay que **gastarlo**:

- HACU_HISTORIAL — mensajes de conversación por turno. Cuesta ~514 tokens cada uno en el presupuesto del peor caso. Es la palanca que ataca «no recuerda lo que acabo de decir».
- broad_results_* y default_results — fragmentos del corpus. ~629 tokens cada uno. Atacan «no encuentra el dato».

Con n_ctx 32 768 el historial admite hasta unos 40 mensajes antes de que verificar_presupuesto aborté. 24 (doce intercambios, frente a los cinco de fábrica) deja 12 664 tokens de margen.

Cambiar **una** de las dos palancas por experimento: con las dos a la vez no se sabe a cuál atribuir la mejora.

Por dónde entrar según lo que quieras cambiar

Quiero...	Empezar por
Cambiar cómo habla HACU	hacu/prompts.py, y después hacu/estilo.py
Añadir o corregir información	documents/, vía <i>El corpus: lo que HACU sabe</i>
Que reconozca un proyecto nuevo por su nombre	Nada: el router lo aprende del índice
Ajustar cuánto recupera	RagConfig en hacu/config.py; medir con pruebas/recuperacion.py
Cambiar la voz o la pronunciación	hacu/voz/pronunciacion.py, VozConfig
Tocar la ventana	hacu/interfaz/, verificable con python -m pruebas.test_unidades interfaz
Cambiar qué se recuerda de los visitantes	hacu/sanitizer.py y MemoryConfig; leer <i>Datos de los visitantes</i>

Configuración

Toda ruta, umbral y límite del proyecto vive en `hacu/config.py`, con la justificación de cada valor al lado. Ningún módulo construye rutas por su cuenta: se les inyecta la configuración. Las rutas son absolutas y derivadas de la raíz del repositorio, así que HACU arranca igual desde cualquier directorio de trabajo.

Quién manda sobre quién

argumentos de la línea de órdenes > variables de entorno > valores por defecto

`run_hacu.aplicar_argumentos()` aplica los argumentos **encima** de lo que ya resolvió `AppConfig.from_env()`. Así, `--sin-voz` gana aunque `HACU_VOZ=1` esté puesta en la sesión.

Variables de entorno

Lo que se puede cambiar sin tocar código ni reinstalar nada.

Variable	Efecto
<code>HACU_DEBUG=1</code>	Diagnóstico en consola: router, perfil, latencia, migraciones
<code>HACU_MODEL0=ruta.gguf</code>	Otro modelo (relativo a <code>models/</code> , o ruta absoluta)
<code>HACU_CTX=8192</code>	Ventana de contexto; un modelo mayor deja menos VRAM
<code>HACU_KV8=1</code>	Caché KV a 8 bits: la mitad de VRAM por token de contexto. Es la palanca que decide si caben 32k (ver <code>herramientas/presupuesto_vram.py</code>)
<code>HACU_HISTORIAL=24</code>	Mensajes de conversación que viajan en cada turno. Subir HACU_CTX sin subir esto no cambia nada: agranda el envase y deja la holgura sin usar
<code>HACU_RETENCION=8</code>	Horas de historial que se conservan (0 desactiva la poda)
<code>HACU_DB=/app/datos/hacu.db</code>	Dónde vive la memoria. En contenedor, apuntar a un volumen montado
<code>HACU_FRAGMENTOS=4</code>	Fragmentos recuperados por consulta normal
<code>HACU_MULTILINGUE=0</code>	Acepta el embedding por defecto de Chroma; degrada el RAG a la mitad
<code>HACU_SALUDO=". . . "</code>	Otra frase de apertura. "" arranca sin saludar

Variable	Efecto
HACU_AYUDA="..."	Recursos de ayuda del centro, para el modo cuidado. Vacío por defecto
HACU_VOZ=1	Activa micrófono y altavoz
HACU_VOZ_SALIDA=1	Solo altavoz: HACU habla pero no escucha
HACU_VOZ_AUTO=1	Escucha automática en vez de pulsar-para-hablar (solo en la ventana)
HACU_HABLANTES=0	No distinguir cuándo cambia la persona que habla
HACU_STT=medium	Tamaño del modelo de reconocimiento: tiny, base, small, medium
HACU_TTS=sistema	Motor de síntesis: auto, piper, piper-proceso, piper-externo, sistema, mudo
HACU_PIPER=ruta.exe	Binario de Piper si no está en el PATH
HACU_VOZ_MODELO=es_ES-davefx-medium	Otra voz de Piper
HACU_ENTRADA=3	Índice del micrófono (ver python -m hacu.voz)
HACU_SALIDA=5	Índice del altavoz
HACU_PAUSA_MS=120	Tope del silencio interno de una frase, en ms (0 deja el audio de Piper tal cual)
HACU_PANTALLA_COMPLETA=1	La ventana arranca a pantalla completa

```
# PowerShell: valen para la sesión actual
$env:HACU_DEBUG="1"; $env:HACU_STT="tiny"
python run_hacu.py --ui --voz
```

```
HACU_DEBUG=1 HACU_STT=tiny python run_hacu.py --ui --voz
```

Argumentos de run_hacu.py

Argumento	Efecto
--debug	Como HACU_DEBUG=1
--ui	Ventana de exhibición en vez de consola
--voz	Micrófono y altavoz
--voz-salida	Solo altavoz
--sin-voz	Fuerza el modo escrito, ganando a las variables de entorno
--pantalla-completa	La ventana arranca a pantalla completa

Los bloques de config.py

ModelConfig — el modelo

Campo	Por defecto	Qué decide
model_path	models/Meta-Llama-3.1-8B-Instruct-GGUF	Qué GGUF se carga
n_ctx	16384	Ventana de contexto
n_gpu_layers	-1	Todas las capas a la GPU
chat_max_tokens	384	Techo de una respuesta normal. La regla 3 pide 2-4 frases y el modelo soltaba monólogos de nueve segundos
chat_max_tokens_extenso	900	Techo cuando se pide desarrollo. Enumerar 32 proyectos no cabe en 384
chat_temperature	0.3	Baja: en una exhibición importa más la fidelidad que la variedad
utility_*	—	Extracción y consolidación de memoria, con salida JSON restringida

RagConfig — el corpus y su recuperación

Campo	Por defecto	Qué decide
doc_folder	documents/	De dónde sale el conocimiento
db_path	chroma_db/	Dónde vive el índice vectorial
chunk_max_seccion	2200	Una ficha ## entra entera si cabe aquí
default_results	6	Fragmentos por consulta normal
broad_results_audacia / _universidad	6 / 8	Consultas amplias
fragmentos_resumen	4	Fichas que acompañan al índice en nivel RESUMEN
fragmentos_centro	6	Fragmentos institucionales en nivel CENTRO
multilingual_model	paraphrase-multilingual-MiniLM-L12-v2	El embedding
exigir_multilingue	True	Aborta el arranque si el multilingüe no está

Sobre esa última: con el embedding por defecto de Chroma —entrenado en inglés— la recuperación sobre el corpus en español baja de 39/39 a 38/39 consultas, y HACU afirmaría no conocer proyectos que sí están documentados. Para una exhibición eso es peor que no arrancar. HACU_MULTILINGUE=0 acepta el modo degradado a sabiendas.

MemoryConfig — la memoria de los visitantes

Campo	Por defecto	Qué decide
db_path	hacu_memory.db	La base SQLite. No se versiona
history_messages	10	Mensajes de historial que viajan al modelo (5 intercambios)
max_facts_per_profile	12	Hechos por visitante
consolidation_threshold	10	Cuándo se depuran los hechos
retencion_horas	24	Al arrancar se borra el historial más viejo. 0 desactiva
sanitize_on_startup	True	Limpia perfiles y hechos inválidos al arrancar

Ver *Datos de los visitantes*.

VozConfig — oído y boca

Detalle completo en *La capa de voz*. Lo que más se toca:

Campo	Por defecto	Qué decide
modelo_stt	small	~0,5 GB de VRAM; convive con el Llama de 8B en 12 GB
vocabulario	AudacIA, Holosand, Orion...	Nombres propios sembrados en el reconocedor
motor_tts	auto	Piper en proceso → Piper externo → voz del sistema → mudo
piper_voz	es_MX-claude-high	Voz descargable con python -m hacu.voz --descargar
pronunciaciones	()	Léxico propio; vacío usa el medido de pronunciacion.py
detectar_cambio_de_hablante	True	Nota cuándo se acerca otra persona, sin identificarla
umbral_hablante	0.65	Misma voz 0,844–0,947; voces distintas 0,314–0,448
minimo_frase / maximo_frase	12 / 240	Troceo del stream en frases pronunciables
deteccion_automatica	False	Escucha automática desde el arranque (solo ventana)

InterfazConfig — la ventana

Campo	Por defecto	Qué decide
pantalla_completa	False	Arrancar a pantalla completa
ancho / alto	1280 / 800	Tamaño de ventana

Campo	Por defecto	Qué decide
tamano_texto	17	Base del texto. En una tarima el público lee de lejos
mostrar_panel_operador	True	Panel derecho visible al arrancar

AppConfig — la raíz

Campo	Por defecto	Qué decide
default_user	visitante	Perfil anónimo
log_file	logs/hacu.log	Dónde va el log
debug_console	False	Diagnóstico en pantalla
saludo_inicial	«Hola, soy Hacu. Bienvenido a AudacIA. ¿Serías tan amable de decirme cuál es tu nombre?»	La primera frase. "" arranca callado
recursos_de_ayuda	""	Adónde mandar a quien lo está pasando mal. Vacío a propósito: lo rellena el centro (<i>Datos de los visitantes</i>)

El saludo de apertura

Es **texto fijo**, no una respuesta del modelo: una frase literal puesta delante de un 8B es exactamente lo que acaba recitando en los turnos siguientes (ver *Contaminación: la regla que más veces se ha roto*).

Sí se registra en el historial como turno de HACU, y eso es lo importante: cuando el visitante conteste «Daniela», el modelo verá la pregunta justo encima. Sin eso, el primer mensaje de la conversación sería un nombre suelto sin nada que lo explique.

Tutea porque la regla 15 obliga a tutear sin cambiar de trato a mitad de conversación, y el saludo entra en el historial: un «usted» ahí arrastraría al modelo a usted durante el resto de la visita. Si se cambia con HACU_SALUDO, conviene mantener el tuteo por el mismo motivo.

En la ventana se repite al pulsar **Nuevo visitante**: quien acaba de acercarse tiene que oír la invitación a decir su nombre.

Cambiar el presupuesto de contexto sin romperlo

Subir HACU_FRAGMENTOS, history_messages o chat_max_tokens_extenso hace crecer el prompt. Si deja de caber en n_ctx, **el arranque se aborta** con ConfiguracionInviabile en vez de truncarse en escena.

```
python -c "from hacu.config import AppConfig; p,d = AppConfig().presupuesto_contexto();
↪ print(f'{p} de {d}')
```

El corpus: lo que HACU sabe

Todo lo que HACU afirma sobre AudacIA y sobre la Universidad Simón Bolívar sale de `documents/`. Si algo no está ahí, HACU tiene que admitir que no lo sabe — y las pruebas comprueban que lo hace.

Los dos niveles

Con 32 proyectos, una sola forma de guardar la información no sirve para todas las preguntas. El corpus está en dos niveles:

Archivo	Nivel	Para qué
<code>audacia_indice_proyectos.md</code>	índice	los 32 proyectos a una línea; sirve para enumerar
<code>audacia_proyectos_salud.md</code>	fichas	una sección ## por proyecto, con su detalle
<code>audacia_proyectos_ambiente.md</code>	fichas	medio ambiente, agro e industria
<code>audacia_proyectos_cultura.md</code>	fichas	cultura, arte y turismo
<code>audacia_proyectos_hardware.md</code>	fichas	hardware, mecatrónica y robótica
<code>audacia_proyectos_educacion.md</code>	fichas	educación y EdTech
<code>audacia_proyectos_energia.md</code>	fichas	energía, servicios públicos y programas estratégicos
<code>audacia_proyectos_didacticos.md</code>	fichas	proyectos didácticos y experimentales
<code>audacia_centro.md</code>	institucional	personas, sedes, patentes, publicaciones, reconocimientos
<code>audacia_centros_hermanos.md</code>	institucional	escrito a mano: MacondoLab y CICV, las unidades que NO son AudacIA
<code>universidad_simon_bolivar.md</code>	institucional	historia, programas, ecosistema Eureka

El nombre del archivo decide el corpus: los que contienen «audacia» van a la colección de AudacIA; el resto, a la institucional. No hay configuración que mantener sincronizada.

La indexación respeta los encabezados ##: cada ficha entra **entera** en un fragmento y no se parte por la mitad. Cada fragmento lleva su tipo (`índice`, `ficha`, `institucional`), y eso es lo que permite pedirle al índice que enumere y a las fichas que expliquen. Ver *Profundidad: la pregunta decide cuánto*

se trae.

El corpus no se escribe a mano

Se genera desde los informes en Word, de modo que actualizar la documentación no obliga a transcribir nada y no se pueden colar datos inventados.

```
# 1. Extraer el texto de los .docx a un JSON intermedio
python herramientas/extraer.py <carpeta con los .docx> fuente.json

# 2. Construir el corpus en dos niveles
python herramientas/construir_corpus.py fuente.json documents/ [corpus_anterior.md]

# 3. MEDIR. Siempre. Antes de comitear nada.
python -m pruebas.recuperacion --n 6 --detalle
```

herramientas/breves.py es lo único escrito a mano **dentro del generador**: el resumen de una línea de cada proyecto para el índice-catálogo. Es compresión editorial de las descripciones del propio informe, y existe porque el índice tiene que caber entero en el contexto para poder enumerar los 32 proyectos de una vez.

Documentos escritos a mano junto a los generados

construir_corpus.py escribe solo los archivos que él nombra y después lista la carpeta, así que **un .md con nombre propio sobrevive a la regeneración**. Es la vía para lo que no está en los informes en Word.

audacia_centros_hermanos.md es el único hoy. Existe porque MacondoLab y el CICV se nombraban en el corpus sin tener nada que los explicara, y HACU contestaba, con razón, que no tenía el dato —falló en las tres corridas de 100 turnos—. El prefijo audacia_ no es decorativo: es lo que manda el archivo a la colección de AudacIA, que es la que consulta una pregunta como «pero MacondoLab es parte de AudacIA, ¿no?».

Tres reglas para añadir otro:

1. **Prefijo audacia_** si debe responder a preguntas sobre el centro; sin él va a la colección institucional.
2. **Una sección ## por tema**, por debajo de chunk_max_seccion (2 200 caracteres) para que entre entera en un fragmento, y con el **título igual al nombre de lo que explica**: a igualdad de palabras compartidas, el rescate léxico prefiere la pieza cuyo título lleva la palabra.
3. **Sin URLs ni notas para el lector dentro del texto**. Un modelo de 8B recita literalmente lo que se le pone delante: se ha observado cuatro veces. Las fuentes van en el commit, no en el corpus.

Y medir siempre después: `python -m pruebas.recuperacion --n 6 --detalle`.

El tercer argumento, y por qué avisa

El detalle técnico de los **proyectos didácticos** nunca estuvo en los informes en Word: se escribió a mano en el corpus anterior (`documents/audacia_unisimón.md`, hoy borrado del árbol). Sin ese archivo el corpus se regenera igual, pero las fichas didácticas salen más pobres que las que hay ahora en disco, y el fallo es silencioso: los archivos aparecen, solo que con menos dentro. Por eso el generador **avisa a gritos** cuando falta.

Si el archivo estuvo alguna vez en el repositorio, se recupera sin resucitarlo:

```
git log --oneline --all -- "documents/audacia_unisimón.md"
git show <commit>:"documents/audacia_unisimón.md" > audacia_anterior.md
python herramientas/construir_corpus.py fuente.json documents/ audacia_anterior.md
```

Después de cambiar el corpus

1. **Reindexar** — no hay que hacer nada: `bootstrap.py` sincroniza al arrancar. Los fragmentos de documentos que ya no están en la carpeta se eliminan del índice, así que borrar un archivo lo borra también del conocimiento de HACU.

2. **Medir la recuperación:**

```
python -m pruebas.recuperacion --n 6 --detalle
```

La referencia actual es **39/39** con el embedding multilingüe (38/39 con el de Chroma por defecto). Una consulta que baja es un proyecto que HACU dejará de encontrar.

3. **Comprobar que el índice sigue completo:** `pruebas/recuperacion.py` verifica que el índice-catálogo entrega los 32 proyectos. Si se añade uno al informe y no a `breves.py`, esa comprobación lo caza.

4. **Correr el guion:**

```
python -m pruebas.conversacion
```

Varios turnos citan datos concretos del corpus; si un dato se movió de sitio, se ve aquí.

Si el índice se queda en un estado raro (por ejemplo tras usar el mismo `chroma_db` desde Windows y desde el contenedor):

```
python -m herramientas.limpiar --aplicar --indice
```

Se reconstruye entero en el siguiente arranque, un par de minutos.

Advertencias de seguridad de cada montaje

HACU tiene una regla de prudencia física: nunca invita a tocar, manipular, abrir, conectar ni llevarse nada a la boca, y ante la duda remite a quien atiende el stand. Eso es **conducta**, y vive en el system prompt.

Lo que **no** hace, y no debe hacer, es inventarse riesgos concretos ni tranquilizar sobre lo que no le consta: decir que una arena es atóxica o que un montaje es apto para niños sin tenerlo documentado es exactamente la clase de invención que el resto del sistema existe para evitar.

Si quieres que avise de algo específico —«no toques los circuitos del Tanque», «la arena de Holosand no se come»— tiene que estar **en el corpus**, y solo lo puede escribir quien conoce el montaje. La vía es una línea más en la ficha del proyecto, dentro del informe en Word del que se genera el corpus:

* ****Seguridad:**** <qué no se debe hacer y por qué, en una frase>

También valen Precaución:, Advertencia: y Cuidado:.

Esa línea **no se queda en el corpus esperando a que el modelo se acuerde**. Al recuperar la ficha, hacu/context.py la extrae y la pone en las notas del turno como instrucción explícita: dila, con naturalidad, sin añadir ninguna que no esté y sin decir que algo es seguro. Con seis fragmentos delante, un 8B se queda con lo vistoso, y la línea de seguridad es justo la que menos luce.

Mientras nadie escriba ninguna, el mecanismo no hace nada: no hay advertencias inventadas por defecto.

Al regenerar, esa línea entra en la ficha y HACU la recupera con el resto del proyecto. Después, medir:

```
python -m pruebas.recuperacion --n 6 --detalle
```

Escribir a mano, si hace falta

Nada impide añadir un .md directamente a documents/. Las reglas:

- **El nombre decide el corpus:** con «audacia» dentro va a AudacIA; si no, a la colección institucional.
- **Una sección ## por unidad de conocimiento.** Es la unidad de recuperación: todo lo que tiene que llegar junto al modelo va bajo el mismo encabezado.
- **Ninguna sección de más de ~2 200 caracteres** (chunk_max_seccion) si se quiere que entre entera en un fragmento.
- **Sin frases de andamiaje.** Lo que se escriba en el corpus puede acabar recitado literalmente por el modelo.
- Después: medir con pruebas/recuperacion.py.

Lo que se añada a mano se pierde en la siguiente regeneración desde los .docx. Si un dato tiene que sobrevivir, tiene que estar en el informe o en breves.py.

La capa de voz

Oído y boca de HACU. Toda la capa es **opcional**: si falta una dependencia o no hay tarjeta de sonido, ServicioDeVoz.disponible es False y HACU sigue funcionando por escrito. Una exhibición sin sonido es mala; una exhibición caída es peor.

Diagnóstico: lo primero que se corre al llegar a la sala

```
python -m hacu.voz                # lista micrófonos y altavoces con su índice
python -m hacu.voz --probar        # graba 3 s y los reproduce
python -m hacu.voz --hablar "Hola, soy Hacu"
python -m hacu.voz --descargar    # baja la voz de Piper configurada
python -m hacu.voz --calibrar     # mide el ruido de la sala

# Sin depender del altavoz ni del micrófono de la máquina
python -m hacu.voz --hablar "Hola, soy Hacu" --guardar prueba.wav
python -m hacu.voz --transcribir grabacion.wav
python -m hacu.voz --autoprueba   # circuito completo sin micrófono
```

El diagnóstico sin argumentos, además de los dispositivos, avisa de lo que falta sin impedir el arranque: la voz de Piper sin descargar y resemblyzer sin instalar. Las dos degradan la exhibición en silencio, y por eso salen aquí y en el arranque de HACU en vez de en un traceback a mitad de conversación.

Se corre **antes de levantar el modelo**. En una portátil con webcam, base de conexiones y auriculares llega a haber cinco entradas de audio, y el sistema no siempre elige la que uno cree. Los índices se fijan con HACU_ENTRADA y HACU_SALIDA para el arranque, o **a mano desde el panel de operador** de la ventana, que es lo cómodo cuando la diadema se conecta con HACU ya en marcha (ver *La ventana de exhibición*).

--guardar vuelca la síntesis a un WAV sin reproducirla y --transcribir hace el camino inverso. Sirven para separar dos fallos que suenan igual: que HACU corte la frase, o que la corte la salida de audio. **Si el WAV está entero, el problema no es de HACU.**

--autoprueba cierra el circuito sin hardware: sintetiza cuatro frases de exhibición con Piper y se las transcribe a sí mismo, comprobando que los nombres propios sobreviven al reconocedor. Es la única forma de saber si el reconocimiento funciona en una máquina donde todavía no hay micrófono.

Reconocimiento

faster-whisper large-v3-turbo en int8, ~1,0 GiB de VRAM: convive con el Llama de 8B dentro de los 12 GB de la portátil (8,20 GiB de los 10,5 disponibles a 16k, según `herramientas.presupuesto_vram --stt large-v3-turbo`).

Por qué ya no es small

Era small y el comentario del código decía que subir «mejora poco en español con audio de cerca». El log de la primera sesión en vivo con voz dice lo contrario:

```
17:57:19 'Explícame cómo es la creatividad general de este'
17:57:31 'explícame la de la actividad general de Einstein'
17:57:48 'Explícame sobre la Relatividad General de Einstein.'
```

Tres intentos para una frase, con el vocabulario ya sembrado y `beam_size=5`. En una sala con ruido, y con visitantes que no van a repetirse tres veces, eso es la exhibición entera: HACU contesta con aplomo a algo que nadie dijo.

large-v3-turbo lleva el **mismo codificador** que large-v3 —que es de donde sale la precisión— con un decodificador de cuatro capas en vez de treinta y dos. 809M parámetros frente a los 244M de small y los 1550M de large-v3.

HACU_STT=small vuelve al anterior sin tocar código, y HACU_STT=tiny es la salida si algún día no cabe.

La confianza del reconocedor, registrada

faster-whisper calcula tres cifras en cada segmento y hasta ahora se tiraban a la basura. Ahora van al log en cada transcripción:

```
Transcrito (83520 muestras) [logprob -0.87 · sin_voz 0.04 · compresion 1.62]: '...'
```

- `logprob`: probabilidad media de los tokens elegidos, en logaritmo. Cerca de 0 es seguro. Es la señal principal.
- `sin_voz`: probabilidad de que el audio no fuera habla.
- `compresion`: muy alta significa texto repetitivo, que es como se ve una alucinación de Whisper.

Manda el segmento **peor**: basta una parte mal oída para dudar de la frase.

No hay ningún umbral todavía, y es deliberado. Para que HACU pida «¿me lo repites?» cuando no entiende hace falta un corte, y ese corte tiene que salir de medir sesiones reales —frases bien oídas contra frases mal oídas— y no de un número elegido a ojo. Un umbral mal puesto interrumpe al visitante cada tres preguntas, que es peor que el problema que arregla. Hay una prueba en el bloque confianza que falla si alguien mete un umbral en la clase sin datos detrás.

La alternativa —preguntarle al modelo de 8B si la frase «tiene sentido»— se descartó: acertaría a medias y cuesta una inferencia entera por turno.

Los nombres propios de la exhibición van sembrados en el prompt inicial del reconocedor (vocabulario en VozConfig), y eso no es una precaución teórica. Medido con --autopruueba, sobre las mismas frases:

Frase	Con vocabulario	Sin vocabulario
«¿Qué proyectos tiene AudacIA?»	AudacIA	«a UDAC ya»
«...sobre Holosand y el sensor Kinect»	Holosand, Kinect	«olo San», «Kinex»

Con el nombre destrozado, el router no reconoce el dominio y HACU responde que no sabe de un proyecto que sí está documentado.

Si el reconocedor no cabe junto al modelo (CUDA out of memory), HACU_STT=tiny baja el consumo, y --voz-salida lo quita del todo.

Síntesis

Piper si está instalado; si no, la voz del sistema operativo (SAPI5 en Windows). El respaldo suena a robot de los noventa, pero existe en cualquier máquina y hace que HACU hable el primer día sin descargar nada.

HACU **no espera a terminar de generar para hablar**: un segmentador trocea el stream en frases y pronuncia la primera mientras el modelo escribe la segunda.

Piper se carga **dentro del proceso**, una sola vez al arrancar. El respaldo que lanza python -m piper por frase sigue ahí, pero solo como último recurso: medido, **0,21 s por frase en proceso frente a 2,52 s lanzando el proceso**, y en una máquina Windows con una voz high esa diferencia sube a más de diez segundos de silencio en cada punto. El arranque dice qué motor se eligió y avisa si acabó en el lento.

HACU_TTS acepta piper-proceso, piper-externo, sistema o mudo para forzar uno.

Cómo se escribe y cómo se dice

hacu/voz/pronunciacion.py reescribe el texto **solo para la voz**, en el último paso antes de sintetizar: la pantalla y la memoria conservan la ortografía real. El visitante ve «AudacIA» y oye «Audacia».

Hace falta porque la ortografía de la exhibición engaña al sintetizador. Medido sintetizando la frase y transcribiendo lo sintetizado, que es la única forma de saber qué sale por el altavoz sin tener a alguien escuchando:

Escrito	Se oía	Se oye ahora
Hacu	«Aku»	«Jacu»
AudacIA	«Uga Ia», «Oda ya»	«Audacia»
IoT	«yote»	«Internet de las Cosas»

Escrito	Se oía	Se oye ahora
3.000 m ²	«temedos»	«metros cuadrados»
OEA	«olla», «Bahía»	«Organización de los Estados Americanos»
SkinIA	«Skinny a»	«Skinia»

Las siglas que el castellano ya deletrea bien (ROV, ROP, PCR, HLB) **no** están en el léxico: no hay reglas de más. «OEA» se dice por su nombre completo porque Piper no la pronuncia en ninguna grafía — se probó OEA, O.E.A. y O E A, y las tres salían mal.

El léxico se amplía sin tocar código con `VozConfig.pronunciaciones`. Si se define, **sustituye** al léxico medido: hay que incluir también las entradas que se quieran conservar.

La pausa que parecía de las tildes

En escena se oía una pausa marcada en las palabras acentuadas, como si el acento partiera la palabra. **No era el acento**. Medido sobre la voz y la versión de Piper de esta máquina:

Qué se comprobó	Resultado
El texto que llega a Piper	NFC limpio, sin acentos descompuestos, sin caracteres de más
La fonemización de <code>espeak-ng</code> (es-419)	Correcta: <code>esta</code> →'esta, <code>está</code> →est'a, <code>investigación</code> →invest,ixasj'on
Huecos con tilde vs. sin tilde	Sin tilde salen <i>más</i> pausas, no menos: la grafía sin acento descoloca el acento tónico
<code>noise_w</code> (variabilidad de duración)	Irrelevante: de 0.0 a 0.8 los huecos no cambian

Lo que sí existe es que el modelo mete **silencios internos de 250 a 450 ms** en los límites prosódicos —«Claro, con gusto.» traía 450 ms en la coma—. En castellano esos límites caen justo detrás de la sílaba tónica, y de ahí la impresión de que la culpa era de la tilde.

`hacu/voz/audio.py` recorta esos huecos a un tope (`pausa_maxima_ms`, 120 ms por defecto, `HACU_PAUSA_MS=0` lo desactiva). Solo toca el aire: recorta el silencio *interno*, deja el del principio y el del final, y **no altera ni una muestra de voz**, así que la acentuación sale idéntica. Medido sobre las mismas frases: el hueco mayor baja de 450 ms a 120 ms y la duración total solo cae un 2,4 %, que es lo que se espera de quitar aire y no de hablar más rápido.

El volumen que subía y bajaba

Piper normaliza **por pico y por frase**, y igualar picos no es igualar sonoridad. Medido sobre nueve frases del mismo audio crudo:

Ajuste de nivel	RMS medio	Dispersión
Por pico (lo que hacía Piper)	0.1635	16.8 %
Por RMS con techo de pico (nivelar)	0.1677	13.9 %

El caso que más se notaba eran las frases cortas: a un «Sí.» la normalización por pico le subía un 35 % la sonoridad respecto de una frase larga. Ahora HACU normaliza por RMS con techo en 0.95, que es lo que juzga el oído, y la sonoridad media se mantiene, así que al actualizar nadie tiene que tocar el volumen.

```
python -m hacu.voz --guardar sigue escribiendo el WAV crudo de Piper, sin recorte ni
nivelado: existe para aislar si el fallo es de la síntesis o de la salida de audio, y para eso hace
falta ver la síntesis sin retocar.
```

Callar a mitad de frase

Callar a HACU **corta de inmediato**, no en el siguiente punto: el audio se entrega a la tarjeta en trozos de 50 ms en vez de frase entera. Medido: **10 ms hasta detenerse y 36 ms de audio ya en vuelo**.

Vale para el botón «Callar a HACU», para Esc, y para cuando el visitante vuelve a pulsar la barra espaciadora para hablar — que es lo importante: quien interrumpe espera que el robot se calle, no que termine la frase.

Quién está hablando

HACU nota cuando **se acerca otra persona** y cierra el perfil anterior, para que el siguiente visitante no herede el nombre ni los hechos del que acaba de irse.

Lo que hace y lo que deliberadamente no hace:

- **No identifica a nadie.** Solo dice «esta es otra voz», nunca «esta es Camila».
- **No guarda nada.** La referencia de timbre vive en memoria durante la visita y se borra al pasar al siguiente visitante o al cerrar. No hay huella de voz en disco, y por tanto no hay base biométrica que custodiar.

La distinción importa: un vector de voz almacenado es un dato biométrico, y esto es una exhibición abierta al público con menores entre el público. Guardarlo sería una decisión de la universidad, no de un commit. Ver *Datos de los visitantes*.

Una frase rara no cambia de visitante

Hacen falta **dos intervenciones seguidas** por debajo del umbral para declarar que hay otra persona. No es prudencia teórica. En la primera sesión en vivo con voz, la misma persona dio estas similitudes, en orden:

```
0.554  ← "Cambio de hablante"
0.678  0.821  0.863  0.903
```

Ese 0.554 le partió el perfil en dos a mitad de conversación —HACU dejó de saber cómo se llamaba— y era un valor atípico contra un timbre construido con una sola frase de tres segundos. Las cuatro siguientes, la misma persona, suben sin parar.

El precio es un turno: si de verdad se acerca otra persona, su primera frase se le atribuye todavía a la anterior. A cambio, una frase con ruido o dicha de lado ya no borra la identidad de quien sí está delante. El contador se reinicia en cuanto vuelve a reconocerse el timbre, así que dos dudas separadas por diez turnos no se suman.

La similitud de cada intervención va al log para poder ajustar el umbral con datos de sala en vez de a ojo.

Si falta `resemblyzer`, se dice **una vez, al arrancar**, y la función queda apagada para la sesión. Antes se reintentaba en cada intervención y escupía el `traceback` entero una vez por turno: en una exhibición eso es una pared de rojo en la consola del operador que no aporta nada después de la primera línea.

Calibrado con dos voces distintas sintetizadas: **misma voz 0,844–0,947, voces distintas 0,314–0,448**, y el umbral por defecto (0,65) cae en medio de ese hueco. Con voces humanas y ruido de sala la separación será menor, así que cada comparación queda en el log para poder recalibrar en la sala. `HACU_HABLANTES=0` lo desactiva.

Pulsar para hablar, y por qué es el modo por defecto

En una tarima el altavoz alimenta al micrófono: con detección automática HACU se oye a sí mismo y se responde solo. No es comodidad, es que el otro modo no funciona en una sala abierta.

La escucha automática está implementada y se activa desde el panel de la ventana —calibra el ruido de sala al encenderla—, pero es para sala controlada o auriculares. `HACU_VOZ_AUTO=1` la activa desde el arranque, y espera a que HACU termine de saludar antes de calibrar: medir el ruido de sala mientras el altavoz está sonando dejaría el umbral por encima de cualquier voz humana.

En consola, la escucha automática no está disponible: se habla con `9` o `v`, que abren el micrófono hasta el siguiente `Enter`.

Solo altavoz

--voz-salida monta la boca y no el oído: no descarga el modelo de reconocimiento ni necesita entrada de audio. Sirve para probar la voz desde una sesión remota, y también el día que el micrófono falle a media jornada — HACU sigue hablando y el operador escribe las preguntas.

Los archivos

Archivo	Responsabilidad
<code>microfono.py</code>	Captura con <code>sounddevice</code> : pulsar-para-hablar y escucha hasta silencio
<code>deteccion.py</code>	Detección de voz por energía. Lógica pura, verificable sin hardware
<code>transcriptor.py</code>	<code>faster-whisper</code> , con el vocabulario sembrado

Archivo	Responsabilidad
sintetizador.py	Piper en proceso, Piper externo, voz del sistema y modo mudo
segmentador.py	Trocea el stream de tokens en frases pronunciables
pronunciacion.py	Léxico de «cómo se escribe / cómo se dice»
audio.py	Recorte de huecos y nivelado por RMS. Aritmética pura, sin altavoz
hablantes.py	Cambio de timbre, efímero y sin identificar
dispositivos.py	Inventario y diagnóstico de audio
__init__.py	ServicioDeVoz: los cuatro verbos que ven la consola y la ventana
__main__.py	El diagnóstico de python -m hacu.voz

Limitaciones conocidas

- El reconocimiento está medido de extremo a extremo con --autoprueba (4/4 nombres propios, ~1,9 s por frase en CPU). Lo que **no** se ha probado es la captura por micrófono real: el nivel de entrada, el ruido de sala y el recorte de la primera sílaba solo se ven con hardware delante.
- Con altavoz abierto, la escucha automática hace que HACU se oiga a sí mismo.
- Una sola estación: hay un perfil activo a la vez.

La ventana de exhibición

```
python run_hacu.py --ui --voz --pantalla-completa
```

Tres zonas, cada una para un público distinto.

Izquierda — el núcleo animado, el botón de hablar y el medidor de nivel. Es lo que ve el visitante desde lejos y lo único que necesita entender.

Centro — la conversación en burbujas, que crece token a token mientras el modelo escribe.

Derecha — los mandos del operador, que se ocultan con F9 para que el público no vea la cocina.

El núcleo cambia de color según el estado: **gris** en espera, **verde** escuchando (los anillos siguen el nivel real del micrófono), **ámbar** pensando, **turquesa** hablando. Es el único indicador que se lee desde el fondo de una sala.

Teclado

Tecla	Efecto
Espacio (mantener)	Hablarle a HACU
Enter en el recuadro	Enviar lo escrito
F9	Ocultar o muestra el panel del operador
F11	Pantalla completa
Ctrl+T	Abrir la transcripción de la conversación
Esc	Callar a HACU en mitad de una frase, y recuperar el teclado
Ctrl+Q	Cerrar (a pantalla completa no hay barra de título)

El teclado se queda en la ventana, no en el recuadro de texto. El recuadro solo lo toma si haces clic en él, y lo suelta al enviar. De lo contrario la barra espaciadora escribía un espacio en vez de abrir el micrófono, y había que hacer clic fuera del recuadro para poder hablarle.

Ctrl+C en la terminal también cierra la ventana, y cierra **bien**: el bucle de eventos de Qt vive en C++ y no devuelve el control al intérprete, así que la señal necesita un latido que le abra hueco y un manejador que pase por el cierre normal, en vez de matar el proceso con el modelo y la base a medias.

Si no hay micrófono, el botón se deshabilita solo y queda el campo de texto: la ventana funciona igual.

El panel del operador (F9)

Visitante

Mando	Qué hace
Etiqueta de perfil	Nombre activo y cuántos hechos recuerda de él. Se refresca sola cada 2 s, porque el extractor de memoria trabaja en segundo plano y termina después del turno
Fijar nombre a mano	Para cuando el reconocimiento destroza un nombre
Nuevo visitante	Cierra el perfil, limpia la pantalla y vuelve a saludar. Es el botón entre visita y visita

Audiencia

Mando	Qué hace
Desplegable	General, Técnico, Infantil o Artístico. Cambia el registro, no el contenido
Modo trivia	HACU propone preguntas sobre la universidad y los proyectos, una a una

Voz

Mando	Qué hace
Escucha automática	Calibra el ruido de sala y escucha sin pulsar nada. Con altavoz abierto HACU se oye a sí mismo: es para sala controlada o auriculares
Callar a HACU	Corta la frase en curso de inmediato (≈ 10 ms). Igual que Esc
Micrófono	Elige por qué entrada oye HACU. Surte efecto en la siguiente escucha, no a mitad de una
Altavoz	Elige por dónde habla. El motor cierra su flujo de audio y lo reabre en la tarjeta nueva, así que surge efecto en la siguiente frase
Buscar dispositivos	Vuelve a inventariar el audio. Para cuando se conecta una diadema con HACU ya arrancado

Los dos desplegables ofrecen siempre **Predeterminado**, que es dejar elegir al sistema, y solo listan lo que sirve: un altavoz no aparece como micrófono. El nombre completo de cada tarjeta está en el *tooltip* de su línea, porque el panel es estrecho y los nombres de PortAudio son largos. Elegir a mano deja constancia en la transcripción, de modo que al revisar una sesión rara se sabe por qué dispositivo entraba y salía el audio.

Esto sustituye a tener que averiguar el índice con `python -m hacu.voz` y relanzar con `HACU_ENTRADA/HACU_SALIDA`. Esas dos variables siguen valiendo para fijar el arranque; el panel las pisa en caliente.

Memoria

Mando	Qué hace
Copiar la conversación	Abre la conversación entera en texto plano, ya seleccionada: <code>Ctrl+C</code> y listo. También la guarda como <code>.txt</code> . Evita tener que capturar la pantalla mensaje a mensaje
Ver lo que recuerda	Los hechos del perfil activo, tal cual están guardados
Limpiar la pantalla	Borra las burbujas y el chat inmediato; conserva los hechos
Borrar TODO	Purga la base entera, con confirmación. No se puede deshacer

Qué pasa al arrancar

1. Se monta la ventana y se aplican los estilos.
2. Se anota cualquier problema de la capa de voz (sin micrófono, motor lento...).
3. Se recuerdan las dos cosas que el operador necesita: la barra espaciadora y `Ctrl+Q`.
4. **HACU saluda**: aparece su primera burbuja y, si hay altavoz, la dice en voz alta.

El saludo es texto fijo, no una respuesta del modelo, pero se registra como turno suyo para que la respuesta del visitante llegue con la pregunta delante. Ver *El saludo de apertura*.

Cómo se verifica sin mirarla

El bloque interfaz de la suite monta la ventana de verdad contra un modelo falso, en el backend offscreen de Qt: corre en cualquier máquina, sin tarjeta gráfica y sin GPU.

```
python -m pruebas.test_unidades interfaz
```

No comprueba que sea bonita —eso se mira— sino que se monta, que el turno llega al hilo correcto, que el texto que se pinta es el mismo que se habla, que los atajos existen, que el foco del teclado se comporta, que la ventana abre saludando y que la transcripción contiene lo que se vio en pantalla.

La transcripción se arma del hilo de burbujas y no de la base de datos, a propósito: la base guarda solo los últimos mensajes y solo los del perfil activo, y lo que interesa copiar es la sesión entera, con los cambios de visitante y los avisos del sistema incluidos.

Los archivos

Archivo	Responsabilidad
ventana.py	La ventana: montaje, estado, turnos, mandos
widgets.py	Núcleo animado, medidor de nivel, botón de hablar, burbujas, métricas
hilos.py	Turnos, transcripción y tareas largas fuera del hilo de Qt
estilos.py	Paleta, hoja de estilos y rótulos de estado

La ventana no sabe nada de llama.cpp, de ChromaDB ni de PortAudio: habla con HacuSession y con ServicioDeVoz, y todo lo lento va a un hilo.

Pruebas

Cinco herramientas, cada una para una pregunta distinta.

Orden	Qué mide	Cuánto tarda	¿GPU?
<code>python -m pruebas.test_unidades</code>	Regresión completa de las capas deterministas y el turno	~2 s	no
<code>python -m pruebas.recuperacion</code>	Calidad del RAG sobre el corpus real	~20 s	no
<code>python -m pruebas.bateria --seco</code>	60 entradas sueltas contra las capas deterministas	~5 s	no
<code>python -m pruebas.bateria --vivo</code>	Las mismas 60 contra el modelo real	minutos	sí
<code>python -m pruebas.conversacion</code>	Una visita completa de 100 turnos encadenados	20-35 min	sí

Después de cada cambio: `test_unidades`. **Antes de una exhibición:** `bateria --vivo` y `conversacion`.

test_unidades — la que se corre siempre

742 comprobaciones, sin GPU, sin red, sin tarjeta de sonido y sin dependencias extra. Cada una existe porque algo se rompió de verdad alguna vez.

```
python -m pruebas.test_unidades          # todo
python -m pruebas.test_unidades estilo   # solo los bloques que casen
python -m pruebas.test_unidades voz saludo
```

Los bloques: routing, seguimiento, nombres, lexico, identity, sanitizer, estilo, calidez, truncado, memory, context, profundidad, cuidado, session, saludo, prompts, guion, cierre, voz, hablantes, pronunciacion, interfaz, config.

El bloque interfaz monta la ventana de verdad en el backend offscreen de Qt, así que corre igual en una máquina sin pantalla. El bloque prompts comprueba la invariante de contaminación: que el system prompt no nombre ningún proyecto del corpus.

Tarda dos segundos y no necesita GPU. **No se comitea en rojo.**

recuperacion — ¿encuentra HACU lo que tiene documentado?

Mide el RAG solo, sin el modelo: 39 consultas contra el corpus real, comprobando que cada una recupera el fragmento que le corresponde.

```
python -m pruebas.recuperacion --n 6 --detalle
```

Referencia actual: **39/39 con el embedding multilingüe, 38/39 con el de Chroma por defecto**. Esa diferencia es la razón de que el arranque se aborte si el multilingüe no está disponible.

Esa consulta que fallaba —«¿Qué publicaciones científicas tienen?»— la arregló el rescate léxico: la sección se llama «Publicaciones científicas» y la palabra es rara en el corpus, así que entra por coincidencia literal aunque el embedding no la acerque.

Ojo con leer demasiado en el 38/39 del embedding en inglés: estas 39 consultas casi siempre nombran lo que buscan («¿Qué es Neupeek?»), que es justo donde el rescate léxico brilla. Una pregunta de tarima que no nombra nada sigue dependiendo del embedding, y por eso el arranque sigue exigiendo el multilingüe.

También comprueba que el índice-catálogo entrega **los 32 proyectos**: si se añade uno al informe y no a herramientas/breves.py, se ve aquí.

Es la prueba que se corre **después de tocar el corpus** (*El corpus: lo que HACU sabe*).

bateria — 60 entradas sueltas

Mide el turno, no la conversación: 60 entradas barajadas, cada una con su intención esperada, su efecto sobre el perfil y su criterio de aceptación.

```
python -m pruebas.bateria --seco           # capas deterministas
python -m pruebas.bateria --vivo          # contra el modelo real
python -m pruebas.bateria --listar        # imprime el catálogo sin ejecutarlo
python -m pruebas.bateria --semilla 7     # fija el orden
```

--vivo usa una base de datos temporal y deja un informe en JSON y CSV en pruebas/informes/. Esos informes **no se versionan**: miden una versión concreta del corpus y envejecen mal.

PRUEBAS.md describe las 60 entradas y su criterio. Se regenera:

```
python -m pruebas.bateria --listar > PRUEBAS.md
```


conversacion — una visita con hilo

La batería mide entradas sueltas y barajadas. Esto mide lo contrario: **una sola visita**, en orden fijo, con un mismo visitante, donde cada turno depende del anterior. Es la prueba que se parece a lo que va a pasar en la tarima.

```
python -m pruebas.conversacion          # los 100 turnos
python -m pruebas.conversacion --listar  # imprime el guion sin ejecutarlo
python -m pruebas.conversacion --desde G51 # segunda mitad
python -m pruebas.conversacion --hasta G50 # primera mitad
python -m pruebas.conversacion --tipo CORRECCION
python -m pruebas.conversacion --voz      # además, hablando
```

Son 100 turnos, entre veinte y treinta y cinco minutos de GPU. Se puede partir en dos sesiones con --hasta G50 y --desde G51.

El guion (pruebas/guion.py) tiene once tipos de turno. Los seis primeros miden **datos**; los cinco últimos miden **conversación**, que es lo que separa a un asistente de exhibición de un buscador con voz:

Tipo	Qué mide	Turnos
ESPECIFICA	dato puntual documentado; la respuesta debe ser corta	23
EXTENDIDA	pide desarrollo; la respuesta debe pasar de ~500 caracteres	5
SEGUIMIENTO	«¿y eso para qué sirve?»: no se sostiene sin el turno anterior	9
CORRECCION	el visitante afirma algo falso y HACU tiene el dato correcto	10
SIN_DATO	no está en el corpus; hay que admitirlo, incluso bajo presión	5
PERSONAL	acoge el nombre, lo recuerda, no revela de dónde lo sabe	4
VAGA	«ajá», «mmm», «¿y eso?», «no entendí»: solo se entiende con el turno inmediatamente anterior	15
AFIRMACION	el visitante afirma en vez de preguntar; hay que reaccionar, no dar una clase	9
NEGATIVA	«no», «no me interesa», «no me repitas»: hay que aceptarlo sin insistir	7
ALEATORIA	fuera de la exhibición; sentido común sin inventar ni sermonear	9
ANCLA	vuelve a algo dicho 30 o más turnos atrás; mide memoria larga	4

Cada turno declara qué términos del corpus **debe** contener la respuesta y qué invenciones **no** puede contener, con comprobación sensible a la negación: «Holosand no usa gafas» no cuenta como haber dicho «gafas».

Cómo se mide perder el hilo. Un turno vago no tiene respuesta única, así que no se puede exigir una. Lo que sí tiene firma observable es el fallo: cuando HACU pierde el hilo, se pone a hablar de otro proyecto. Por eso casi todos los turnos VAGA prohíben explícitamente el nombre de proyectos que no vienen a cuento, y la suite comprueba que ninguno se queda sin exigir ni prohibir nada — un turno vago que lo acepta todo no mide nada.

Regresiones cubiertas por turnos concretos:

- G54–G56: la alucinación del observatorio astronómico, el desafío de fuentes que la siguió y la presión social («mi profesor no me va a mentir»).
- G75–G79: los niveles de profundidad — contar los proyectos, desglosarlos y corregir una cifra mal entendida.
- G42, G89–G91: las anclas largas. G91 pregunta a noventa turnos de distancia si el dron volaba: es la comprobación de que HACU no se contradice a sí mismo a lo largo de una visita entera.
- G50 y G96: recordar lo que dijo el visitante de sí mismo (que estudia Sistemas), no solo su nombre.
- G03, G06, G20, G45 y G72: prohíben **irse a cualquier proyecto** del catálogo y **abandonar el hilo** («eso queda fuera de mi área»). Con una lista de cinco nombres se escapaba lo importante: en la corrida del 21/09 un «Ajá.» se fue a hablar de Vallenato Master y **el turno aprobó**.
- G63, G92 y G99: **literales de la sesión con público del 21/09/2026**, no inventados. El injerto de Einstein («cuéntame de la universidad, pero antes explícame la relatividad»), y los dos cierres largos que se colaban por el tope de 12 palabras. G99 prohíbe además «has mencionado» y «has entendido»: ahí HACU le atribuyó al visitante tres proyectos que nunca nombró.

GUIÓN.md es la versión legible del guion. Se regenera:

```
python -m pruebas.conversacion --listar > GUIÓN.md
```

Cómo leer un fallo

Un fallo de test_unidades es **siempre** un fallo del código: no hay modelo detrás, todo es determinista.

Un fallo de batería --vivo o de conversacion puede ser del código o del modelo. Antes de tocar nada, repetir ese turno solo:

```
python -m pruebas.conversacion --desde G17
```

Si el fallo no se repite, era variabilidad del modelo. Si se repite, es real.

Y hay una tercera posibilidad, que ha pasado varias veces: **el criterio de la prueba estaba mal**. Un turno que exige la palabra «cultivo» cuando el corpus dice «agricultura» falla sin que nada esté

roto. Antes de cambiar el sistema, leer la respuesta completa y preguntarse si de verdad está mal.

Limpiar después

```
python -m herramientas.limpiar          # lista lo prescindible
python -m herramientas.limpiar --aplicar # lo borra
```

Los informes de pruebas, el log y el bytecode se acumulan entre corridas. La base de memoria y el índice vectorial van aparte (--memoria, --indice) porque uno son datos de personas y el otro cuesta un par de minutos de reconstrucción.

El día de la exhibición

Guion de operación: qué hacer antes de abrir, durante la jornada y al cerrar.

La noche anterior

```
cd D:\Proyectos\voz-rag-universidad
.\env\Scripts\Activate.ps1

python -m pruebas.test_unidades      # 742 en verde
python -m pruebas.recuperacion        # 39/39
python -m pruebas.conversacion        # la visita completa, contra el modelo real
```

Si la conversación falla en algún turno, hay tiempo de mirarlo. A las nueve de la mañana con público delante, no.

Comprobar que el modelo está donde se espera y que la GPU lo acepta:

```
python -c "from llama_cpp import llama_supports_gpu_offload as g; print('GPU:', g())"
```

Y comprobar que arranca sin red, que es como va a estar la sala. Desconecta el Wi-Fi y arranca: el embedding del RAG y el reconocedor se abren desde la caché, así que tiene que levantar igual. Si se queda esperando a huggingface.co, falta descargar algo y hay que hacerlo **hoy**, con red, no mañana en el montaje.

Al llegar a la sala, antes de levantar el modelo

Primero el audio. Es lo que más falla y lo más rápido de diagnosticar.

```
python -m hacu.voz      # ¿qué micrófono y qué altavoz hay?
python -m hacu.voz --probar      # graba 3 s y los reproduce
python -m hacu.voz --hablar "Hola, soy Hacu. Bienvenido a AudacIA."
```

`python -m hacu.voz` también lista lo que falta sin impedir el arranque: la voz de Piper sin descargar y resemblyzer sin instalar. Las dos degradan la exhibición en silencio —pausas largas entre frases y un detector de visitante que nunca dispara— así que si aparecen, se arreglan hoy.

En una portátil con webcam, base de conexiones y auriculares llega a haber cinco entradas. Si el sistema no elige la correcta, se fija por índice:

```
$env:HACU_ENTRADA="3"
$env:HACU_SALIDA="5"
```

Si el arranque avisa de que el motor de síntesis es el lento (piper-externo), hay pausas de segundos en cada punto:

```
python -m hacu.voz --descargar
```

Arrancar

```
python run_hacu.py --ui --voz --pantalla-completa
```

El arranque tarda: carga el modelo en la VRAM, sincroniza el corpus y precalienta. Termina en [OK] Sistema listo, HACU saluda y queda a la espera.

Si algo no arranca, hay tres escalones de respaldo, cada uno más pequeño:

Problema	Respaldo
Falla el micrófono	python run_hacu.py --ui --voz-salida — HACU habla, el operador escribe
Falla todo el audio	python run_hacu.py --ui — solo texto, la ventana funciona igual
Falla la ventana	python run_hacu.py — la consola hace lo mismo
Falla la GPU	Arranca en CPU: un turno tarda minutos. No sirve; mejor cancelar la demostración que enseñar eso

Durante la jornada

Entre visitante y visitante

Nuevo visitante en el panel (F9 si está oculto). Cierra el perfil, limpia la pantalla y vuelve a saludar. Sin eso, el siguiente hereda el nombre y los hechos del anterior.

Si el visitante habla por micrófono, HACU lo hace solo: nota el cambio de timbre y cierra el perfil sin que nadie pulse nada.

Ajustar al público

El desplegable **Audiencia** cambia el registro sin cambiar el contenido: *General* por defecto, *Infantil* con un colegio, *Técnico* con profesores o ingenieros, *Artístico* con gente de humanidades.

Modo trivia convierte a HACU en el que pregunta. Funciona muy bien con grupos de niños y con colas.

Cuando se pone pesado

Esc o **Callar a HACU** corta la frase de inmediato. También corta volver a pulsar la barra espaciadora: el visitante que interrumpe no tiene que esperar.

Cuando alguien lo está pasando mal

Si un visitante menciona suicidio o hacerse daño, HACU **no improvisa**: responde un texto fijo que le remite a ti, y te avisa en la pantalla con «[!] Atención: el visitante ha dicho algo que necesita una persona, no un robot».

Cuando veas ese aviso, acércate. No hay nada que tocar en el sistema; lo que hace falta eres tú. Ten localizado antes de abrir a quién de Bienestar Universitario puedes llamar ese día.

Si el centro te ha dado unos recursos concretos, configúralos antes de arrancar para que HACU los diga:

```
$env:HACU_AYUDA="Bienestar Universitario: <dónde y cómo>. Línea de apoyo: <cuál>."
```

Vacío, HACU remite solo a ti, que es la respuesta correcta en cualquier caso.

Cuando dice algo raro

HACU está construido para admitir que no sabe algo, y las pruebas lo verifican. Si aun así afirma algo que no está en el corpus, es un fallo que merece anotarse: la pregunta exacta y lo que respondió. Queda en `logs/hacu.log` con marca de tiempo.

Lo que **no** hay que hacer es discutir con él delante del público. **Nuevo visitante** y seguir.

Para dejar constancia de una conversación entera —un fallo que reportar, un intercambio que salió bien y quieres guardar— **Ctrl+T** abre la transcripción en texto plano, lista para copiar o guardar como `.txt`. Es más rápido y más fiel que capturar la pantalla mensaje a mensaje.

Si se queda colgado

Ctrl+Q en la ventana, o **Ctrl+C** en la terminal. Cierra bien: drena la cola de memoria, cierra la base y suelta la VRAM. Volver a arrancar tarda menos que la primera vez —el corpus ya está indexado— pero sigue siendo un minuto largo.

Al cerrar

La transcripción de las conversaciones se borra sola al arrancar cuando supera las `retencion_horas` (24 por defecto). Los hechos de cada perfil se conservan.

Si la política del centro es **no conservar nada** de la jornada:

```
python -m herramientas.limpiar --aplicar --memoria
```

O desde el panel, **Borrar TODO**.

Ver *Datos de los visitantes* antes de decidir. Es una decisión de la universidad, no del operador.

Chuleta

Situación	Tecla o mando
Hablarle	Mantener Espacio
Callarlo	Esc
Ocultar el panel del operador	F9
Entrar o salir de pantalla completa	F11
Siguiente visitante	Botón Nuevo visitante
Cerrar	Ctrl+Q
Copiar la conversación entera	Ctrl+T , o botón Copiar la conversación
Ver lo que recuerda de alguien	Botón Ver lo que recuerda
Borrar todo	Botón Borrar TODO

Datos de los visitantes

HACU guarda información de las personas que hablan con él. Esta página dice qué, dónde, cuánto tiempo y quién decide.

Qué se guarda

Dato	Dónde	Cuánto dura
Transcripción reciente de la conversación	<code>hacu_memory.db</code>	Se borra al arrancar pasadas <code>retencion_horas</code> (24 por defecto)
Hechos extraídos («se llama Daniela», «estudia ingeniería»)	<code>hacu_memory.db</code>	Hasta que alguien los borre
Registro de ejecución con las preguntas	<code>logs/hacu.log</code>	Hasta que alguien lo borre
Referencia de timbre de voz	Solo en memoria RAM	Se borra al cambiar de visitante o al cerrar

`hacu_memory.db` y `logs/` están en `.gitignore` y **no se versionan nunca**.

Cuando alguien lo está pasando mal

Pasa, y ya pasó en la primera prueba: un visitante contó que había perdido a sus padres, que se sentía solo, y acabó diciendo que se iba a suicidar.

HACU tiene una capa **determinista** para eso (`hacu/cuidado.py`). Ante una mención de suicidio o de hacerse daño, **el modelo no interviene**: responde un texto fijo, escrito y revisable, que remite a la persona que atiende el stand y no ofrece proyectos ni inventa teléfonos. Ante malestar declarado —tristeza, soledad, ansiedad— sí responde el modelo, pero con la instrucción explícita de reconocer lo que le han contado y de **no** reconducir a la exhibición.

Lo que eso significa para los datos:

- **Lo que dijo el visitante no se escribe.** En el historial queda [mensaje sensible, no registrado]. Es información de salud mental de alguien que pasaba por una exhibición y no tiene por qué acabar en un SQLite.
- **No entra en la memoria episódica.** Ni el turno de crisis ni el de malestar se encolan para extraer hechos del perfil.

- **El operador se entera en el momento**, con un aviso en la pantalla y en el log. Esa es la parte que importa: la respuesta correcta es una persona.

Los recursos de ayuda concretos —teléfonos, Bienestar Universitario— **están vacíos por defecto** y los rellena el centro con `HACU_AYUDA` o `AppConfig.recursos_de_ayuda`. Un número de crisis inventado es peor que ninguno, y en esa primera prueba el modelo ofreció, por su cuenta, un servicio de ayuda **en Venezuela** estando el montaje en Barranquilla.

Esto es una red de seguridad, no un protocolo. Antes de abrir al público, el centro tiene que decidir qué hace el personal del stand cuando esto ocurra, y quién de Bienestar Universitario está localizable ese día. El software avisa; atender es de las personas.

Qué NO se guarda

- **Ninguna huella de voz en disco.** El detector de cambio de hablante compara el timbre de lo que se acaba de decir con el de la frase anterior, en memoria, y lo olvida al pasar al siguiente visitante. No dice «esta es Camila», solo «esta es otra voz».

La distinción es lo que separa este sistema de uno biométrico. Un vector de voz almacenado **es** un dato biométrico, y esto es una exhibición abierta al público con menores entre el público. Guardarlo sería una decisión de la universidad, no de un commit.

- **Nada sale de la máquina.** No hay llamadas a ninguna API: el modelo, el índice y la memoria son locales.

Qué filtra el sistema por su cuenta

`hacu/sanitizer.py` decide qué merece guardarse como hecho. Descarta lo que no es información sobre el visitante: afirmaciones sobre terceros, intentos de inyección («a partir de ahora te llamas Pepito»), meta-texto del modelo y fragmentos de sus propios prompts. `pruebas/test_unidades.py` lo verifica en el bloque `sanitizer`.

`identity.py` valida los nombres antes de crear un perfil: no todo lo que suena a nombre lo es, y un reconocimiento defectuoso puede producir cualquier cosa.

Cómo se borra

Alcance	Consola	Ventana	Línea de órdenes
Chat inmediato del perfil activo	2	Limpiar la pantalla	—
Memoria del perfil activo	6	—	—
Toda la base	7	Borrar TODO	<code>python -m herramientas.limpiar --aplicar --memoria</code>

El borrado de toda la base pide confirmación y no se puede deshacer.

Lo que hay que decidir antes de una exhibición real

Esto es una implementación, no una política. Antes de abrir al público, alguien de la universidad tiene que decidir:

1. **Si se conservan los hechos entre jornadas.** Ahora sí: es lo que permite que HACU reconozca a alguien que vuelve. Si la respuesta es no, hay que purgar al cerrar cada día.
2. **Cuántas horas se conserva la transcripción.** 24 por defecto (HACU_RETENCION).
3. **Si se informa a los visitantes** de que la conversación se recuerda durante la visita, y cómo: un cartel junto al montaje es lo habitual.
4. **Qué pasa con los menores.** Parte del público de una exhibición universitaria son niños de colegio, y el tratamiento de sus datos tiene reglas propias (Ley 1581 de 2012 y su decreto reglamentario).
5. **Si el log se conserva.** Registra las preguntas de los visitantes con marca de tiempo. Es útil para depurar y es un registro de conversaciones.

La opción más conservadora, y la que no necesita consultar a nadie, es purgar al cerrar:

```
python -m herramientas.limpiar --aplicar --memoria
```